

SKRIPSI

KOMPARASI ALGORITMA RNN DAN LSTM PADA PREDIKSI
BERAT SAMPAH HARIAN TPA KABUPATEN MAGELANG



AWALINA ROSA PARAMITA

NPM. 20.0504.0042

PROGRAM STUDI TEKNIK INFORMATIKA S1

FAKULTAS TEKNIK

UNIVERSITAS MUHAMMADIYAH MAGELANG

AGUSTUS, 2024

SKRIPSI
KOMPARASI ALGORITMA RNN DAN LSTM PADA
PREDIKSI BERAT SAMPAH HARIAN TPA
KABUPATEN MAGELANG

Disusun Sebagai Salah Satu Syarat Memperoleh Gelar Sarjana Komputer(S.Kom)

Program Studi Teknik Informatika Jenjang Strata Satu (S-1) Fakultas Teknik

Universitas Muhammadiyah Magelang



AWALINA ROSA PARAMITA

20.0504.0042

PROGRAM STUDI INFORMATIKA S1
FAKULTAS TEKNIK
UNIVERSITAS MUHAMMADIYAH MAGELANG
2024

HALAMAN PENEGASAN

Skripsi ini adalah hasil karya saya sendiri, dan semua sumber baik yang dikutip maupun dirujuk telah saya nyatakan dengan benar.

Nama : Awalina Rosa Paramita
NPM : 20.0504.0042

Magelang, 23 Agustus 2023

A handwritten signature in black ink, consisting of a series of loops and a final horizontal stroke.

Awalina Rosa Paramita


20.0504.0042

HALAMAN PENGESAHAN
SKRIPSI
KOMPARASI ALGORITMA RNN DAN LSTM PADA
PREDIKSI BERAT SAMPAH HARIAN TPA
KABUPATEN MAGELANG

Disusun oleh :
Awalina Rosa Paramita
NPM 20.0504.0042

Telah dipertahankan di depan Dewan Penguji
Pada tanggal 23 Agustus 2024

Susunan Dewan Penguji


Pembimbing I


Nurvanto, S.T., M.Kom
NIDN. 0605037002


Pembimbing II


Pristi Sukmasetva, S.Komp., M.Kom
NIDN. 0618129201

Penguji I


Dr. Uky Yudiantama, S.Si., M.Kom., M.M.
NIDN. 0605107201

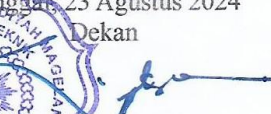
Penguji II


R. Arri Widyanto, S.Komp., M.T.
NIDN. 0616127102

Skripsi ini telah diterima sebagai salah satu persyaratan
untuk memperoleh gelar Sarjana Komputer

Tanggal 23 Agustus 2024
Dekan




Nurvanto, S.T., M.Kom.
NIDN. 987008138

PERNYATAAN KEASLIAN

Yang bertanda tangan dibawah ini:

Nama : Awalina Rosa Paramita

NPM : 20.0504.0042

Program Studi : Teknik Informatika S1

Fakultas : Teknik

Alamat : Kajangkoso RT 001/ RW 001, Kajangkoso, Pakis

Judul Skripsi : Komparasi Algoritma RNN dan LSTM pada Prediksi Berat Sampah Harian TPA Kabupaten Magelang

Dengan ini menyatakan bahwa skripsi ini merupakan hasil karya sendiri dan bukan merupakan plagiat dari hasil karya orang lain. Bila di kemudian hari terbukti bahwa skripsi ini merupakan plagiat karya orang lain, maka saya bersedia menerima sanksi baik secara administrasi maupun sanksi lainnya.

Demikian surat pernyataan ini saya buat dengan penuh kesadaran dan penuh tanggung jawab.

Magelang, 23 Agustus 2023

Yang menyatakan,



Awalina Rosa Paramita

20.0504.0042

SURAT PERNYATAAN TIDAK UNGGAH REPOSITORI

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ

Yang bertanda tangan di bawah ini, saya:

Nama : Awalina Rosa Paramita

NPM : 20.0504.0042

Fakultas/ Jurusan : Teknik/Teknik Informatika S1

Jenis : TA / Skripsi / Tesis

Judul Skripsi/ TA : KOMPARASI ALGORITMA RNN DAN LSTM PADA PREDIKSI BERAT SAMPAH HARIAN TPA KABUPATEN MAGELANG

Dengan ini menyatakan bahwa:

1. Memberikan hak menyimpan, mengalih-media/ format-kan, mengelola dalam bentuk pangkalan data (databased) kepada Perpustakaan Universitas Muhammadiyah Magelang
2. **Tidak memberikan ijin** kepada Perpustakaan Universitas Muhammadiyah Magelang untuk mengunggah (upload) naskah Skripsi/TA di Repositori Perpustakaan Universitas Muhammadiyah Magelang **dikarenakan**;

Akan diupload ke tempat lain oleh dosen pembimbing.

Demikian pernyataan ini saya buat dengan sesungguhnya dan semoga dapat digunakan sebagaimana mestinya.

Magelang, 23 Agustus 2024

Pembimbing,

Yang Menyatakan,



Pristi Sukmasetya, S.Komp., M.Kom
NIDN. 0618129201



: Rosa Paramita
20.0504.0042

Mengetahui,
Ketua Program Studi Teknik Informatika S1

Fakultas Teknik



: Nur Hafidha, S.T., M.Eng

NIK. 168208163

KATA PENGANTAR

Puji syukur dipanjatkan ke hadirat Allah SWT, karena atas berkat nikmat dan karunia-Nya, Skripsi ini dapat diselesaikan. Penyusunan skripsi ini dilakukan dalam rangka memenuhi salah satu syarat untuk mencapai gelar Sarjana Komputer (S.Kom) Program Studi Teknik Informatika S1 Fakultas Teknik Universitas Muhammadiyah Magelang.

Penyelesaian skripsi ini banyak memperoleh bantuan dan bimbingan dari berbagai pihak. Oleh karena itu, diucapkan terima kasih kepada:

1. Dr. Lilik Andriyani selaku Rektor Universitas Muhammadiyah Magelang.
2. Nuryanto, S.T., M.Kom selaku Dekan Fakultas Teknik Universitas Muhammadiyah Magelang.
3. Setiya Nugroho, S.T., M.Eng. selaku Ketua Program Studi Teknik Informatika S1 Universitas Muhammadiyah Magelang.
4. Nuryanto, S.T., M.Kom selaku dosen pembimbing I dan Pristi Sukmasetya, S.Komp., M.Kom, selaku dosen pembimbing II, yang telah memberikan bimbingan, kritik, saran, dan arahan selama proses penyusunan skripsi.
5. Pihak pengelola TPA Kabupaten Magelang yang telah banyak membantu dalam usaha memperoleh data yang diperlukan.
6. Orang tua yang senantiasa mendoakan dan selalu memberikan semangat.
7. Para sahabat yang telah banyak membantu penyelesaian skripsi ini.

Akhir kata, penulis berharap semoga skripsi ini dapat memberikan manfaat bagi semua pihak yang membacanya.

Magelang, 23 Agustus 2024,



Awalina Rosa Paramita

20.0504.0042

DAFTAR ISI

HALAMAN KULIT MUKA	i
HALAMAN JUDUL	ii
HALAMAN PENEGASAN	iii
HALAMAN PENGESAHAN	iv
PERNYATAAN KEASLIAN	v
HALAMAN PERNYATAAN PUBLIKASI	vi
KATA PENGANTAR	vii
DAFTAR ISI	viii
DAFTAR TABEL	x
DAFTAR GAMBAR	xi
DAFTAR LAMPIRAN	xii
INTISARI	xiii
<i>ABTRACT</i>	xiv
BAB 1 PENDAHULUAN	1
1.1 Latar Belakang Permasalahan	1
1.2 Rumusan Masalah	3
1.3 Tujuan Penelitian	3
1.4 Manfaat Penelitian	4
BAB 2	5
TINJAUAN PUSTAKA	5
2.1 Penelitian Relevan	5
2.2 Landasan Teori	7
2.2.1 Sampah	7
2.2.2 Tempat Pemrosesan Akhir	8
2.2.3 Prediksi	10
2.2.4 <i>Recurrent Neural Network</i>	10
2.2.5 <i>Long Short Term Memory</i>	14
BAB 3	19
METODOLOGI PENELITIAN	19
3. 1 Prosedur Penelitian	19
3. 2 Hipotesis	20
3. 3 Tahap Rancangan Percobaan	21

3. 4 Tahap Pengujian	23
BAB IV	24
HASIL DAN PEMBAHASAN	24
4.1 Hasil	24
4.2 Pembahasan	29
BAB V	44
KESIMPULAN DAN SARAN	44
5.1 Kesimpulan	44
5.2 Saran	44
DAFTAR PUSTAKA	46
LAMPIRAN	48

DAFTAR TABEL

Tabel 4. 1 Dataset TPA Kabupaten Magelang	24
Tabel 4. 2 Missing Value	29
Tabel 4. 3 Parameter	31
Tabel 4. 4 Perbandingan Akurasi Algoritma RNN dan LSTM	32
Tabel 4. 5 Perbandingan Efektivitas RNN dan LSTM	34

DAFTAR GAMBAR

Gambar 2.1 Keadaan TPA Pasuruhan	9
Gambar 2.2 TPA Klegen	9
Gambar 2.3 Proses Penimbangan	10
Gambar 2.4 Arsitektur RNN	11
Gambar 2.5 Arsitektur Pemrosesan RNN	12
Gambar 2.6 Arsitektur LSTM	15
Gambar 4. 1 Data Berat Sampah TPA Kabupaten Magelang	24
Gambar 4. 2 Library	25
Gambar 4. 3 Koneksi	25
Gambar 4. 4 Info Dataset	26
Gambar 4. 5 Info Data 2	27
Gambar 4. 6 Data sebelum Normalisasi	27
Gambar 4. 7 Data setelah Normalisasi	28
Gambar 4. 8 Berat Sampah kondisi Idul Fitri 2021	37
Gambar 4. 9 Berat sampah Kondisi Idul Fitri 2022	38
Gambar 4. 10 Berat Sampah Kondisi Idul Fitri 2023	39
Gambar 4. 11 Prediksi Berat Sampah Idul Fitri 2024	40
Gambar 4. 12 Berat Sampah Kondisi Idul Adha 2021	41
Gambar 4. 13 Berat Sampah Kondisi Idul Adha 2022	42
Gambar 4. 14 Berat Sampah Kondisi Idul Adha 2023	43
Gambar 4. 15 Prediksi Berat Sampah pada Idul Adha 2024	44

DAFTAR LAMPIRAN

1. Kondisi TPA Kabupaten Magelang	48
-----------------------------------	----

INTISARI

Nama : Awalina Rosa Paramita

Program Studi : Teknik Informatika S1

Judul : Komparasi Algoritma RNN dan LSTM pada Prediksi Berat Sampah
Harian TPA Kabupaten Magelang

Permasalahan sampah merupakan permasalahan global yang menjadi masalah serius. Permasalahan sampah seperti yang terjadi di Kabupaten Magelang dimana rata-rata perhari sampah yang dibuang ke Tempat Pembuangan Akhir Pasuruhan Kabupaten Magelang yaitu berkisar ± 63.9 kg/hari. Berat sampah tersebut mengakibatkan adanya perpindahan TPA karena daya tampung yang tidak memungkinkan lagi TPA Kabupaten Magelang dialihkan ke TPA Klegen. Prediksi berat sampah dapat digunakan untuk menentukan dan merancang langkah yang dilakukan kedepannya agar masalah sampah dapat tertangani dengan baik, selain itu pola pembuangan sampah pada hari-hari besar dapat dilihat untuk dapat dilakukan antisipasi. Penelitian ini menggunakan data dari TPA Kabupaten Magelang berupa data berat harian sampah yang masuk ke TPA Kabupaten Magelang. metode yang digunakan pada penelitian ini berupa algoritma RNN dan LSTM yang akan dibandingkan untuk mengetahui akurasi dan efektifitas masing-masing algoritma. Hasil penelitian menunjukkan bahwa algoritma RNN mencapai nilai *Root Mean Square Error* (RMSE) terendah sebesar 43696,105 dengan efisiensi waktu terendah 53,477 detik sedangkan algoritma LSTM mampu mencapai nilai RMSE terendah sebesar 39886,819 dengan efisiensi yang terendah pada 114,723 detik.

Kata Kunci: Sampah, Prediksi, RNN, LSTM

ABTRACT

Awalina Rosa Paramita

Teknik Informatika (S1)

Comparison of RNN and LSTM Algorithms for Daily Waste Weight Prediction of Magelang Regency Landfill

Waste problem is a global problem that has become a serious problem. Waste problems such as those that occur in Magelang District where the average daily waste disposed to Pasuruhan Landfill in Magelang District is around ± 63.9 kg/day. The weight of the waste resulted in the transfer of the landfill because the capacity of the landfill was no longer possible, and the landfill was transferred to Klegen landfill. The prediction of waste weight can be used to determine and design the steps taken in the future so that the waste problem can be handled properly, besides that the pattern of waste disposal on big days can be seen to be anticipated. This research uses data from the Magelang Regency Landfill in the form of daily weight data of waste entering the Magelang Regency Landfill. The methods used in this research are the RNN and LSTM algorithms which will be compared to determine the accuracy and effectiveness of each algorithm. The results showed that the RNN algorithm achieved the lowest Root Mean Square Error (RMSE) value of 43696.105 with the lowest time efficiency of 53.477 seconds while the LSTM algorithm was able to achieve the lowest RMSE value of 39886.819 with the lowest efficiency at 114.723 seconds.

Keywords: Garbage, Prediction, RNN, LSTM

BAB 1

PENDAHULUAN

1.1 Latar Belakang Permasalahan

Tempat akhir yang digunakan untuk mengumpulkan dan memproses sampah pada suatu wilayah disebut dengan Tempat Pembuangan Sampah Akhir (Axmalia & Mulasari, 2020). Tempat Pembuangan Sampah Akhir atau yang biasa disebut dengan Tempat Pemrosesan Akhir Sampah (TPA) yang berada pada sebagian besar wilayah di Indonesia menerapkan sistem pembuangan sampah sederhana yang mana sampah hanya dikumpulkan pada suatu wilayah yang terbuka. Sistem *open dumping* tersebut juga diterapkan pada TPA yang berada di Kabupaten Magelang. Pemerintah Kabupaten Magelang memiliki Tempat Pemrosesan Sampah Akhir (TPA) bernama TPA Pasuruhan yang terletak di Dusun Bojong, Desa Pasuruhan, Kecamatan Mertoyudan, Kabupaten Magelang, Jawa Tengah. TPA Pasuruhan memiliki lahan seluas 3 hektar, namun karena banyaknya sampah yang masuk dan tidak tertangani dengan baik maka lahan TPA Pasuruhan tidak dapat lagi menampung sampah yang masuk, sehingga TPA Kabupaten Magelang dialihkan dari TPA Pasuruhan menuju TPA Klegen mulai November 2023.

Pembuangan sampah yang dilakukan di TPA Klegen disebabkan karena lahan pembuangan sampah pada TPA Pasuruhan telah melebihi kapasitas lahan. Timbunan sampah di TPA Pasuruhan yang melebihi kapasitas diakibatkan belum adanya mesin pengolah sampah, sehingga semakin hari semakin banyak sampah yang menumpuk. Penimbunan sampah dapat mengakibatkan timbulnya emisi gas ruang kaca yang berdampak negatif terhadap lingkungan (Anifah et al., 2021). Ketidakmungkinan lagi lahan di TPA Pasuruhan untuk menampung lebih banyak sampah membuat adanya perpindahan lokasi TPA Kabupaten Magelang menjadi di TPA Klegen yang berada di Dusun Kupa, Desa Baleagung, Kecamatan Grabag, Kabupaten Magelang, Jawa Tengah 56196. Perpindahan TPA secara keseluruhan dimulai pada Januari 2024 dimana seluruh kegiatan mulai dari penimbangan, pembuangan, dan pembayaran dilakukan di TPA Klegen.

Perpindahan Tempat Pembuangan Akhir (TPA) Kabupaten Magelang dari Pasuruhan sebagai solusi terhadap keterbatasan kapasitas lahan telah menciptakan masalah baru. Praktik *open dumping* atau pembuangan terbuka yang hanya memindahkan sampah dari satu lokasi ke lokasi lain dapat menimbulkan dampak negatif terhadap lingkungan dan kesehatan masyarakat. Informatika dapat memainkan peran penting dalam pengelolaan sampah yang lebih baik. Teknologi big data dan *machine learning* dapat dimanfaatkan untuk melakukan Prediksi berat sampah. Data berat sampah dapat dikumpulkan dan dilakukan analisis data historis mengenai berat sampah dari berbagai wilayah. Data ini kemudian diproses menggunakan algoritma prediktif untuk menghasilkan estimasi yang akurat mengenai berat sampah di masa mendatang.

Sampah yang dibuang pada TPA Pasuruhan dan Klegen berasal dari berbagai kecamatan yang berada di Kabupaten Magelang. Sampah tersebut berupa sampah organik dan anorganik baik yang berasal dari sisa rumah tangga, sampah pasar, dan sampah yang dihasilkan dari sisa kegiatan industri. Sampah tersebut belum dapat tertangani dengan benar sehingga menimbulkan timbunan sampah dimana semakin hari timbunan sampah semakin banyak. Suatu materi buangan atau sisa yang tidak digunakan dan dipakai kembali disebut sampah (Taufiq & Maulana, 2015). Pemanfaatan data yang tersedia pada Tempat Pembuangan Akhir (TPA) Kabupaten Magelang yang baru telah digunakan secara signifikan dalam lingkup kesehatan masyarakat. Data historis mengenai berat sampah yang dihasilkan, yang mencakup rata-rata 85 ton sampah per hari, belum dianalisis.

Data runtun waktu atau *time series* merupakan data yang terkumpul berdasarkan urutan waktu dalam rentang waktu tertentu. Data runtun waktu dapat diterapkan untuk melakukan peramalan kemungkinan keadaan yang akan datang yang dapat digunakan untuk pengambilan keputusan (Tauryawati & Irawan, 2014). Data berat sampah harian merupakan data runtun waktu *time series* yang dapat dilakukan prediksi. Penelitian terdahulu telah membahas prediksi berat sampah dengan menggunakan beberapa metode seperti metode *neural network backpropagation* dengan tingkat MSE terkecil 0.048 dan metode *Support Vector Machine* dengan tingkat kesalahan 0.108 (Purnamaswari et al., 2022). Penelitian lain yang menggunakan algoritma *neural network* berupa algoritma *Long-Short*

Term Memory (LSTM) menghasilkan nilai *Mean Square Error* (MSE) terkecil 0.220207 setelah melewati 500 *epoch* (Manikari et al., 2024).

Melihat permasalahan yang ada dan beberapa penelitian terdahulu, maka akan dilakukan penelitian tentang implementasi algoritma *Recurrent Neural Network* (RNN) dan *Long-Short Term Memory* (LSTM) untuk melakukan prediksi berat sampah di Tempat Pemrosesan Akhir Sampah (TPA) Kabupaten Magelang. Prediksi berat sampah dilakukan untuk mengetahui perkiraan berat sampah harian agar otoritas pengelola dapat merencanakan dan mengalokasikan sumber daya yang dimiliki secara efisien. Prediksi berat sampah dapat membantu pengelola TPA Kabupaten Magelang, DLH Kabupaten Magelang, dan Kementerian Lingkungan Hidup untuk mengambil langkah-langkah preventif untuk mengurangi dampak lingkungan yang terjadi akibat sistem TPA *open dumping*. Penumpukan sampah pada TPA lahan terbuka (*open dumping*) menimbulkan berbagai masalah lingkungan dan kesehatan.

1.2 Rumusan Masalah

Berdasarkan latar belakang permasalahan di atas, maka masalah penelitian ini dirumuskan sebagai berikut :

1. Bagaimana akurasi prediksi berat sampah harian di Tempat Pemrosesan Akhir Sampah (TPA) Kabupaten Magelang dengan algoritma *Recurrent Neural Network* (RNN) dan *Long Short Term Memory* (LSTM) untuk melihat pola berat sampah pada hari-hari besar?
2. Bagaimana efisiensi algoritma *Recurrent Neural Network* (RNN) dan *Long Short Term Memory* (LSTM) dalam melakukan prediksi berat sampah harian di Tempat Pemrosesan Akhir Sampah (TPA) Kabupaten Magelang untuk melihat pola berat sampah pada hari-hari besar?

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah, maka tujuan penelitian yang akan dicapai adalah sebagai berikut:

1. Untuk mengetahui akurasi prediksi berat sampah harian di Tempat Pemrosesan Akhir Sampah (TPA) Kabupaten Magelang dengan algoritma *Recurrent Neural Network* (RNN) dan *Long Short Term Memory* (LSTM) untuk melihat pola berat sampah pada hari-hari besar.
2. Untuk mengetahui perbandingan efisiensi algoritma *Recurrent Neural Network* (RNN) dan *Long Short Term Memory* (LSTM) dalam melakukan prediksi berat sampah harian di Tempat Pemrosesan Akhir Sampah (TPA) Kabupaten Magelang melihat pola berat sampah pada hari-hari besar.

1.4 Manfaat Penelitian

Berdasarkan tujuan penelitian yang telah disebutkan di atas, maka hasil penelitian ini dapat memberikan manfaat sebagai berikut:

1. Manfaat Teoritis

Manfaat teoritis dari penelitian ini yaitu penelitian ini diharapkan dapat menambah teori atau konsep yang dapat menyokong ilmu pengetahuan tentang metode dan teknik pemodelan prediksi berat sampah khususnya pada pengembangan model prediksi dengan algoritma *Recurrent Neural Network* (RNN) dan *Long Short Term Memory* (LSTM) dan penerapannya pada data urutan waktu.

2. Manfaat Praktis

Melalui penelitian ini diharapkan dapat memiliki dampak langsung dalam kehidupan sehari-hari. Penelitian ini diharapkan dapat membantu pihak pengelola Tempat Pemrosesan Akhir Sampah (TPA) dan pihak pengelola TPA Kabupaten Magelang, DLH Kabupaten Magelang, dan Kementerian Lingkungan Hidup untuk memahami pola produksi sampah yang dihasilkan dan dapat membuat kebijakan yang tepat untuk merencanakan dan melakukan pengelolaan operasional TPA agar sampah yang ada tidak mengalami penumpukan.

BAB 2

TINJAUAN PUSTAKA

2.1 Penelitian Relevan

Penelitian relevan yang mendasari penelitian ini antara lain sebagai berikut. Penelitian Niken Priandila, Darjad Saripurna, dan Magdalena Simanjuntak (2022) menjelaskan bahwa metode *Backpropagation* dapat digunakan untuk memprediksi jumlah sampah di Kabupaten Langkat. Penelitian tersebut dilakukan iterasi sebanyak 73 kali untuk menyesuaikan target yang ditetapkan. Penelitian ini melakukan prediksi dengan melakukan pelatihan jaringan syaraf tiruan yang terkontrol untuk melakukan prediksi sampah di Kecamatan Bahorok, Kabupaten Langkat. Prediksi sampah pada wilayah tersebut pada tahun depan diperkirakan akan mencapai 250,175 m³ dengan akurasi 75,0% (Priandila et al., n.d.).

Penelitian oleh Anak Agung Arimas Purnamaswari, I Ketut Gede Darma Putra, dan I Made Sujiwa Putra (2022) tentang perbandingan metode *Neural Network Backpropagation* dan *Support Vector Machine* untuk melakukan prediksi sampah. Data yang digunakan pada penelitian ini merupakan data sampah yang ditampung pada Tempat Pembuangan Sampah akhir Suwung, Bali mulai tahun 2015 hingga 2020. Penelitian ini melakukan pengujian parameter tertentu untuk mengoptimalkan hasil peramalan baik untuk prediksi dengan metode *Backpropagation* maupun metode *Support Vector Machine* (SVM). Penelitian ini menghasilkan kesimpulan bahwa metode *Backpropagation* yang memiliki tingkat kesalahan terkecil 0.048 dan metode *Support Vector Machine* dengan tingkat kesalahan 0.108 (Purnamaswari et al., 2022).

Metode prediksi *Recurrent Neural Network* dan *Long Short Term Memory* mampu melakukan prediksi dengan baik pada prediksi *time series*. Metode *Recurrent Neural Network* digunakan oleh Akhdan Aziz Ghozi, Ayu Aprianti, Ahmad Dzaki Putra Dimas, dan Rifky Fauzi (2022) dalam penelitian tentang prediksi data kasus Covid-19 di Provinsi Lampung. Penelitian tersebut

menggunakan tiga kasus berbeda, dimana kasus pertama menggunakan RNN arsitektur 75-25-20 dengan *epoch* sebanyak 250 kali. Kasus kedua menggunakan RNN arsitektur 20-25-20 dengan *epoch* sebanyak 250 kali dan pada kasus ketiga menggunakan RNN arsitektur 50-25-20 dengan *epoch* sebanyak 100 kali (Ghozi et al., 2022).

Metode prediksi *Long Short Term Memory* digunakan oleh Alfredi Yoani, Sediono, M. Fariz Fadillah Mardianto, dan Elly Pusporani (2023) untuk memprediksi jumlah kejadian banjir. Dalam penelitian ini pada *cell forget gate* LSTM menggunakan fungsi aktivasi *sigmoid* dan nilai pembobot *forget gate* untuk nilai $ht-1$ dan nilai xt . Penelitian tersebut menunjukkan bahwa metode LSTM dapat digunakan untuk melakukan suatu prediksi *time series* dengan menghasilkan nilai *Root Mean Square Error* sebesar 5.911. Penelitian tersebut menghasilkan nilai *R2 training* sebesar 95.71%. Jumlah *epoch* pada penelitian tersebut sebanyak 650 kali untuk mendapat kesimpulan bahwa nilai *validation loss* terendahnya perada pada *epoch* ke 431 (Yoani et al., 2023).

Selain itu, penelitian yang dilakukan oleh Salsa Loni Manikari, Rini Astuti, Fadhil Muhammad Basysyar, dan Agusbaciari (2024) yang melakukan penelitian tentang prediksi berat sampah pada TPA Gunung Santri Kabupaten Cirebon. Penelitian tersebut menggunakan algoritma *Long Short Term Memory* dan dilakukan beberapa percobaan untuk menghasilkan model terbaik. Penelitian tersebut menghasilkan akurasi yang cukup baik dalam memprediksi berat sampah dengan menggunakan arsitektur *Long Short Term Memory* berupa 128 *neuron*, 30 input layer, dan melakukan pelatihan model sebanyak 500 *epoch*. Arsitektur tersebut menghasilkan nilai MSE terkecil pada penelitian tersebut yaitu 0.220207 setelah melewati 500 *epoch* (Manikari et al., 2024).

Berdasar pada beberapa penelitian yang telah dilakukan jumlah berat sampah pada masa yang akan datang dapat diketahui dengan melakukan sebuah prediksi menggunakan berbagai algoritma. Algoritma *Recurrent Neural Network* dapat digunakan untuk melakukan perhitungan prediksi *time series* begitu juga dengan algoritma *Long Short Term Memory*. Berdasarkan literatur penelitian yang telah dilakukan, akan dilakukan penelitian berkaitan dengan analisis kinerja algoritma *Recurrent Neural Network* dan algoritma *Long Short Term Memory* untuk

prediksi berat sampah harian. Penelitian ini memiliki perbedaan dengan penelitian-penelitian terdahulu yang membahas tentang prediksi berat sampah, terutama pada dua aspek yaitu dataset yang digunakan dan algoritma. Dataset yang digunakan untuk melakukan prediksi didapatkan dari TPA Kabupaten Magelang. Algoritma yang digunakan dalam penelitian ini tidak hanya mengandalkan algoritma yang telah digunakan pada penelitian prediksi berat sampah sebelumnya seperti algoritma *Long Short Term Memory* (LSTM), tetapi digunakan juga algoritma *Recurrent Neural Network* (RNN) yang memiliki performa baik dalam melakukan pengolahan dan analisis data runtun waktu.

2.2 Landasan Teori

2.2.1 Sampah

Segala sesuatu yang kurang bernilai dan bernilai, atau sisa dari hal yang tidak berguna merupakan definisi dari sampah (McDougall et al., 2001). Sampah dapat bertambah selama adanya kehidupan yang berhubungan dengan pola konsumsi yang mempengaruhi peningkatan berat, karakteristik dan jenis sampah (Nurhajati, 2022). Dilihat dari segi lingkungan, sampah dapat mengakibatkan gangguan terhadap lingkungan hidup. Berdasarkan kamus istilah lingkungan hidup, sampah didefinisikan sebagai materi yang tidak memiliki nilai, materi yang tidak berharga, pemakaian bahan rusak, barang cacat dalam pembuatan, materi yang berlebihan, atau materi yang ditolak. Sampah secara garis besar dibagi menjadi tiga macam yaitu (Sejati, 2009):

1. Sampah organik

Sampah organik adalah sampah yang berasal dari makhluk hidup dan dapat terdegradasi. Sampah organik meliputi sampah dapur, daun-daunan, sisa sayuran, sisa buah, dan lain lain.

2. Sampah anorganik

Sampah anorganik adalah sampah yang tidak dapat terurai secara alami. Sampah anorganik meliputi sampah plastik, karet, besi, logam, botol, kaleng, dan lain sebagainya.

3. Sampah berbahaya

Sampah berbahaya meliputi limbah racun kimia, limbah nuklir, baterai, limbah medis, dan sebagainya. Sampah jenis ini memerlukan penanganan khusus.

Sampah tidak akan hilang selama adanya kehidupan di bumi. Peningkatan berat sampah merupakan jenis, ragam, spesifikasi, dan karakteristik sampah yang bertambah seiring waktu berjalan bermunculan material dan bahan baru yang membutuhkan sistem penanganan yang berbeda (Kahfi, 2017). Sampah elektronik dan buangan lainnya yang dikategorikan sebagai limbah bahan berbahaya dan beracun (B3) memiliki penanganan yang berbeda dan lebih spesifik dari sampah plastik atau kaleng yang merupakan sampah domestik biasa (Kahfi, 2017).

2.2.2 Tempat Pemrosesan Akhir

Undang-Undang No. 18 Tahun 2008 tentang Pengelolaan Sampah mengatur penyelenggaraan pengelolaan sampah yang diwenangkan kepada beberapa pihak terkait (Pemerintah Indonesia, 2008). Pasal 9 Undang-Undang Pengelolaan Sampah memberikan wewenang kepada Pemerintah Kabupaten/Kota untuk menetapkan lokasi Tempat Pemrosesan Akhir (TPA) dengan dilakukan pemantauan dan evaluasi berkala. TPA adalah suatu tempat yang disediakan untuk penampungan dan pemrosesan akhir sampah pada suatu wilayah kabupaten/kota (Axmalia & Mulasari, 2020).

Tempat Pemrosesan Akhir merupakan lokasi yang tidak hanya digunakan untuk melakukan pembuangan akhir sampah, tetapi meliputi empat kegiatan utama di lokasi TPA untuk pengelolaan sampah, meliputi pemilahan sampah, *recycle* sampah non-organik, pengomposan sampah organik, dan akumulasi limbah residu di lokasi penimbunan (Pemerintah Indonesia, 2008). Kabupaten Magelang memiliki Tempat Pemrosesan Akhir Sampah (TPA) yang semula berada di TPA Pasuruhan kemudian dipindahkan ke TPA Klegen. Kondisi yang tidak memungkinkan lagi bagi TPA Pasuruhan untuk menampung sampah mengakibatkan perpindahan tersebut. Gambar 2.1 Keadaan TPA Pasuruhan merupakan keadaan TPA Pasuruhan dimana lahan yang ada penuh dengan sampah yang menumpuk bahkan hingga menggunung. Sampah yang menggunung

diakibatkan oleh sampah yang masuk ke TPA Pasuruhan hanya ditimbun saja tanpa dilakukan proses untuk menguraikannya.



Gambar 2.1 Keadaan TPA Pasuruhan


Perpindahan TPA Pasuruhan ke TPA Klegen dimulai dari Juli 2023 dengan hanya sampahnya yang dibuang ke TPA Klegen tetapi operasional penimbangan sampah masih berada di TPA Pasuruhan. Operasional secara keseluruhan oleh TPA Klegen dimulai pada Januari 2024. TPA Klegen merupakan TPA open dumping dengan luas area sekitar 1 hektar yang terletak di Kupa, Baleagung, Kecamatan Grabag, Kabupaten Magelang. Gambar 2.2 TPA Klegen merupakan visualisasi keadaan TPA Klegen, pada tumpukan sampah yang ada di area TPA Klegen terdapat alat berat berupa ekskavator. Alat berat tersebut digunakan untuk meratakan, mengumpulkan, atau memindahkan sampah ke area tertentu, menghindari penumpukan yang berlebihan dan menjaga kebersihan serta keteraturan di area tersebut.



Gambar 2.2 TPA Klegen

TPA Klegen dan TPA Pasuruhan pada dasarnya memiliki proses bisnis yang sama. Proses bisnis yang dilakukan dimulai dari pengumpulan sampah dari berbagai wilayah kecamatan yang diangkut menggunakan truk, pick up, dan tosa. Penimbangan sampah yang masuk ke TPA dilakukan pada jembatan timbang

elektronik yang akan terhubung langsung dengan sistem yang memunculkan berat sampah beserta harga sampah seperti pada gambar 2.3 Proses Penimbangan dibawah. Pihak penyeter sampah membayar sejumlah harga yang sesuai dengan berat sampah yang dibawa. Harga sampah per kilogram adalah 500 rupiah.



Gambar 2.3 Proses Penimbangan

2.2.3 Prediksi


Prediksi atau peramalan adalah suatu usaha untuk menduga atau memperkirakan suatu hal yang akan terjadi pada waktu yang akan datang dengan memanfaatkan informasi yang relevan dari waktu lampau dengan menggunakan metode ilmiah (Wanto & Windarto, 2017). Prediksi memiliki tujuan untuk mendapatkan suatu informasi yang akan terjadi diwaktu yang akan datang dengan probabilitas kejadian terbesar. Metode prediksi memiliki beragam metode yang banyak dan seringkali memerlukan asumsi untuk dipenuhi (Achmalia & Sugiman, 2020). Metode prediksi dapat dilakukan dengan salah satunya menggunakan metode prediksi kuantitatif dengan menggunakan analisis deret waktu (*time series*) (Nurmahaludin, 2014).

2.2.4 Recurrent Neural Network

Algoritma *Recurrent Neural Network* (RNN) adalah algoritma *machine learning* yang memiliki basis ekstraksi fitur data yang terperinci (Yu et al., 2018). Cara kerja algoritma RNN memiliki kesamaan arsitektur dengan algoritma *Multi-Layer Perception* (MLP) dimana cara kerjanya meniru cara kerja otak manusia

sehingga dapat mengirimkan informasi antar neuron. Algoritma RNN merupakan pengembangan dari Jaringan Syaraf Tiruan (Yu et al., 2018). RNN dibuat untuk data-data yang memiliki sifat *sequential* atau bertahap (Tarkus, 2020). Algoritma neural network biasanya tidak memiliki ketergantungan antara input dan output secara langsung yang berpengaruh pada penumpukan tugas yang banyak (Li et al., 2012).


Karakteristik unik RNN dimana arsitekturnya memiliki *feedback loop* yang dapat menyimpan data pada suatu struktur jaringan, sehingga performa RNN ketika melakukan prediksi bergantung pada arsitektur serta bobotnya. RNN memiliki perulangan dalam arsitekturnya, di mana pada setiap langkah waktu t , RNN menyimpan input x_t dan memperbarui keadaan vektor h_t dari keadaan sebelumnya h_{t-1} . Ketika ada input baru, perhitungan dilakukan berdasarkan vektor h_t , dan proses ini berulang, membentuk jejak urutan (*history of sequence*) (Alim, 2023). RNN memiliki parameter yang dapat mempengaruhi seperti *epoch* dan *batch size*. *Epoch* merupakan parameter ketika seluruh dataset sudah melalui proses training hingga kembali ke awal pada sekali putaran. *Batch size* merupakan jumlah sampel data yang disebarkan pada algoritma,



Gambar 2.4 Arsitektur RNN

RNN memiliki jaringan *node* yang dimasukan ke dalam layer yang berurutan dengan setiap node dalam suatu lapisan terhubung dengan koneksi terarah ke setiap node lain secara berurutan (Jain et al., 2016). Pada gambar 2.5 Arsitektur Pemrosesan RNN merupakan diagram arsitektur pemrosesan RNN, terlihat bahwa inputan data pada input layer akan diteruskan ke dalam *hidden layer*. *Hidden Layer* merupakan lapisan yang terletak diantara input dan output yang berfungsi untuk melakukan pemrosesan data. *Hidden layer* memiliki garis *looping* yang mengarah kembali pada *hidden layer* tersebut, pola *looping* tersebut memungkinkan algoritma RNN untuk menyimpan memori sementara yang akan

dipakai dalam pemrosesan data. Pemrosesan data yang dilakukan akan ditampilkan hasilnya pada output layer (Tarkus, 2020).



Gambar 2.5 Arsitektur Pemrosesan RNN

Algoritma RNN memiliki langkah-langkah dalam mengolah data yaitu inisialisasi, input dan *hidden state*, menghitung *forward pass*, menghitung *loss calculation*, dan menghitung *backward pass*. Lebih lengkapnya langkah algoritma RNN dalam mengolah data adalah sebagai berikut.

Langkah 1:

Menentukan bobot dan bias awal.

Langkah 2:

Menghitung input x_t pada waktu t dan *hidden state* sebelumnya h_{t-1} .

Langkah 3:

Menghitung *hidden state* pada h_t dengan fungsi aktivasi yang dirumuskan sebagai berikut:

$$h_t = \tanh(W_{xh} * x_t + W_{hh} * h_{t-1} + b_h) \dots \dots \dots (1)$$

Keterangan

h_t = *hidden state* pada waktu t

W_{xh} = bobot yang menghubungkan input x_t dengan *hidden state* h_t

x_t = input pada waktu t

W_{hh} = bobot yang menghubungkan *hidden state* sebelumnya dengan *hidden state* saat ini

h_{t-i} = *hidden state* sebelumnya

b_h = nilai bias

Output pada waktu t dapat dirumuskan sebagai berikut:

$$y_t = W_{hy} * h_t + b_y \dots \dots \dots (2)$$

Keterangan

y_t = *output* pada waktu t

W_{hy} = bobot yang menghubungkan *hidden state* h_t dengan *output* y_t

h_t = *hidden state* pada waktu t

b_y = bias

Langkah 4:

Menghitung *loss calculation* menggunakan *output* y_t dan target sebenarnya y_t menggunakan *Mean Square Error* (MSE) dengan rumus sebagai berikut:

$$MSE = \frac{1}{n} \sum_1^n (A_i - F_i)^2 \dots \dots \dots (3)$$

Keterangan:

n adalah ukuran sampel

A_i adalah nilai data aktual ke- i

F_i adalah nilai data peramalan ke- i

Langkah 5:

Menghitung gradien dan memperbaharui bobot dengan rumus:

$$\frac{\partial L}{\partial W_{hy}} = (y_t - \hat{y}) * h_t \dots \dots \dots (4)$$

Keterangan:

$\frac{\partial L}{\partial W_{hy}}$ adalah *gradient* fungsi *loss function* L terhadap bobot W_{hy}

$(y_t - \hat{y})$ adalah selisih *error* antara output aktual dan target prediksi

h_t adalah *hidden state* pada waktu t

Pembaruan bobot dapat dirumuskan sebagai berikut

$$W_{hy} = W_{hy} - \eta * \frac{\partial L}{\partial W_{hy}} \dots \dots \dots (5)$$

W_{hy} adalah bobot yang menghubungkan *hidden state* h_t dengan output y_t

η adalah *learning rate*

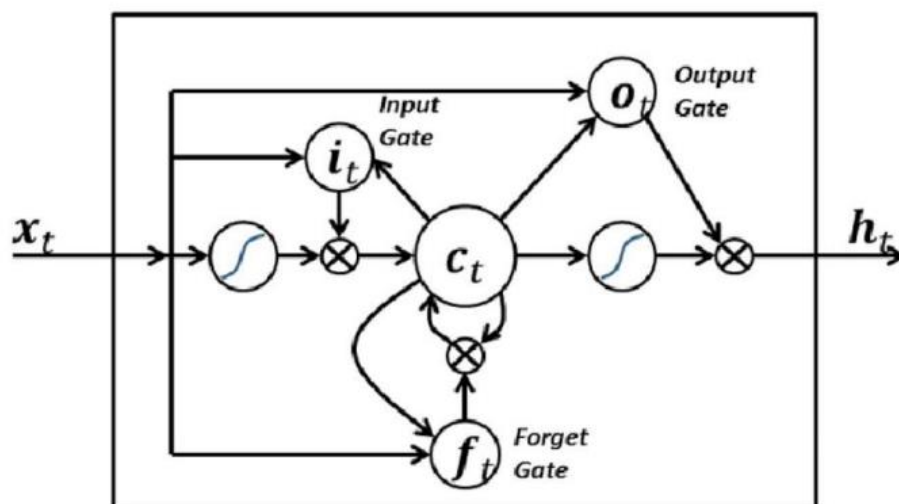
$\frac{\partial L}{\partial W_{hy}}$ adalah gradien fungsi *loss function* L terhadap bobot W_{hy}

2.2.5 Long Short Term Memory

Long Short Term Memory (LSTM) adalah algoritma yang diperkenalkan oleh Hochreiter dan Schmidhuber pada tahun 1997 yang merupakan evolusi dari arsitektur RNN (Selle et al., 2022). Sama seperti RNN, LSTM terdiri dari modul dengan pemrosesan berulang. Model ini terdiri dari beberapa sel yang disebut sebagai input sel, output sel, dan *forget* sel. Setiap sel memiliki tanggung jawabnya sendiri dalam mengingat informasi selama interval waktu yang bervariasi. LSTM (*Long Short-Term Memory*) terdiri dari berbagai sub-jaringan rekuren yang saling terhubung, yang biasa disebut sebagai blok memori. Kelebihan utama LSTM dibandingkan dengan RNN adalah kemampuannya dalam mengatasi masalah *vanishing gradient* dan *exploding gradient*, yaitu masalah di mana perubahan bobot (*weight*) menjadi terlalu kecil atau terlalu besar. Sejumlah pengembangan lebih lanjut dari metode LSTM telah dilakukan, termasuk beberapa metode baru yang sering digunakan (Alim, 2023).

Arsitektur LSTM merupakan pengembangan dari arsitektur RNN dimana *hidden layer* pada RNN akan berbentuk seperti *cell* yang memiliki fungsi untuk

mengingat memori masa lalu. Arsitektur LSTM memiliki isi *cell* yang lebih kompleks dibandingkan dengan RNN. Banyaknya isi *cell* pada LSTM membuat model dari algoritma LSTM mampu mencegah kondisi *vanishing gradient*, sehingga model dapat mempelajari pola panjang dari data *time series* (Sugiartawan et al., 2018). Arsitektur LSTM seperti yang ditunjukkan ilustrasinya pada Gambar 2.6 Arsitektur LSTM berikut menunjukkan bahwa pada *cell* LSTM memiliki dua hasil nilai luaran. Luaran pertama adalah luaran sebenarnya yang akan dilanjutkan kembali ke *cell* berikutnya dan menjadi *output* dari *cell* tersebut. Sistem LSTM ini memiliki tiga buah pintu atau *gates* berupa *input*, *forget* dan *output gate* (Sugiartawan et al., 2018).



Gambar 2.6 Arsitektur LSTM

Langkah metode LSTM dalam melakukan Prediksi meliputi menghapus informasi dari cell state, menyimpan informasi pada cell state, dan memasukkan output dari cell state. Penjelasan langkah metode LSTM adalah sebagai berikut:

Langkah 1:

Menentukan bobot dan bias awal.

Langkah 2:

Memutuskan informasi yang akan dihapus dari *cell state*. Keputusan itu dibuat oleh layer sigmoid yang bernama layer *forget gate*, layer tersebut akan memproses h_{t-1} dan x_t sebagai input. *Forget gate* dirumuskan secara matematis sebagai berikut:

$$f_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_f) \dots \dots \dots (6)$$

Dengan,

i_t merupakan *input gate*,

W_i merupakan nilai *weight* untuk *input gate*, dan

b_i merupakan nilai bias pada *input gate*.

Langkah 3:

Memutuskan informasi yang akan disimpan dalam *cell state*. Langkah ini terdapat dua bagian, bagian pertama yaitu *input gate* layer akan memutuskan nilai mana yang akan diperbarui dimana *tanh* layer akan membuat satu kandidat nilai baru. *Input gate* dapat dijabarkan sebagai berikut:

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t]) + b_i \dots \dots \dots (7)$$

Dimana,

i_t merupakan *input gate*

W_i merupakan nilai *weight* untuk *input gate*

b_i merupakan nilai bias pada *input gate*

Bagian kedua yaitu output dari layer *input gate* dan layer *tanh* digabungkan untuk memperbarui *cell state*.

$$C_t = f_t \cdot C_{t-1} + i_t \cdot C_t \dots \dots \dots (8)$$

Keterangan,

C_t merupakan *cell state*

f_t merupakan *forget gate*

C_{t-1} merupakan nilai baru yang ditambahkan ke *cell state*

Langkah 4:

Output dimasukkan dari *cell state* kedalam layer tanh dan dikalikan dengan sigmoid *gate* agar output yang dihasilkan sesuai dengan yang diputuskan sebelumnya. Formula output *gate* diuraikan sebagai berikut:

$$o_t = \sigma(W_o[h_{t-1}, x_t] + b_o) \dots \dots \dots (9)$$

Dengan,

o_t merupakan output *gate*

W_o merupakan nilai berat untuk output *gate*

b_o merupakan nilai bias pada output *gate*

2.2.6 Root Mean Square Error

Root mean square error mengevaluasi prediksi dengan melakukan pengakaran dari pengkuadratan kesalahan-kesalahan kemudian dilakukan penjumlahan dan ditambahkan dengan jumlah observasi. RMSE dapat digunakan untuk mengukur akurasi, dimana semakin kecil nilai RMSE semakin baik akurasi yang dihasilkan. Rumus dari RMSE yaitu:

$$RMSE = \sqrt{\frac{1}{n} \sum_1^n (A_i - F_i)^2} \dots \dots \dots (10)$$

Keterangan:

n adalah ukuran sampel

A_i adalah nilai data aktual ke- i

F_i adalah nilai data peramalan ke- i

2.2.7 *Runtime*


Runtime adalah periode waktu ketika suatu program berjalan. Ini dimulai ketika suatu program dibuka (atau dieksekusi) dan diakhiri dengan program berhenti atau ditutup. Istilah *runtime* paling sering digunakan dalam pengembangan perangkat lunak. Ketika program berada dalam fase *runtime*, aplikasi dimuat ke RAM, termasuk file yang dapat dieksekusi dan perpustakaan apa pun yang dirujuk oleh program.

BAB 3

METODOLOGI PENELITIAN

3.1 Prosedur Penelitian

Tahapan atau prosedur penelitian yang akan dilakukan dijelaskan pada Gambar 3.1 Tahapan Penelitian yang menunjukkan tahapan penelitian yang akan dilakukan.



Gambar 3. 1 Tahapan Penelitian

Tahapan pertama pada penelitian ini berupa studi literatur, tahapan ini dimulai dari menentukan topik penelitian yang akan diangkat, mencari sumber referensi yang relevan, memahami literatur, dan mensintesis informasi dari sumber referensi. Studi literatur pada penelitian ini mencakup beberapa kajian yang membahas penggunaan algoritma *Recurrent Neural Network* (RNN) dan *Long Short Term Memory* (LSTM) dalam melakukan prediksi data time series. Beberapa studi penelitian sebelumnya telah menunjukkan keberhasilan algoritma *Recurrent Neural Network* (RNN) dan *Long Short*

Term Memory (LSTM) dalam melakukan prediksi terhadap dataset time series berupa prediksi jumlah bencana, prediksi kasus covid-19, dan analisa finansial.

Prosedur penelitian kedua yaitu observasi yang dilakukan pada 13 Maret 2024 di TPA Klegen yang berada di Grabag dan observasi TPA Pasuruhan di Mertoyudan. Observasi tersebut menghasilkan informasi bahwa lokasi TPA Kabupaten Magleng mengalami perpindahan dari TPA Pasuruhan ke TPA Klegen, hal tersebut disebabkan kapasitas lahan TPA Pasuruhan yang sudah tidak bisa menampung lagi sampah yang dihasilkan di wilayah Kabupaten Magelang. Penumpukan sampah tersebut terjadi karena sampah hanya ditampung di TPA Pasuruhan tanpa adanya pengelolaan sampah yang efektif untuk mengurangi tumpukan sampah.

Prosedur penelitian ketiga yaitu pengumpulan data. Penelitian ini menggunakan dataset yang diambil langsung dari TPSA Klegen dengan data masukan berupa total berat sampah per-harinya selama 3 tahun mulai dari Januari 2021 sampai dengan Desember 2023. Dataset yang digunakan terdiri dari 1095 data. Wawancara yang dilakukan pada saat pengambilan data kepada petugas TPA menghasilkan informasi bahwa data berat sampah yang ada terdapat beberapa data yang kosong dikarenakan ada beberapa masalah yang sering terjadi. Masalah tersebut berupa pemadaman listrik dan timbangan rusak.

Prosedur penelitian keempat yaitu pengolahan data, dalam penelitian ini data akan diolah dengan tahapan berupa *preprocessing* data untuk mengatasi *missing value*, pembagian data menjadi data *training* dan data *testing*, data diolah untuk menghasilkan model dengan menggunakan algoritma RNN dan LSTM. Prosedur penelitian kelima yaitu penyajian hasil. Hasil model RNN dan model LSTM yang telah didapatkan dilakukan analisa dan ditampilkan untuk mengetahui kinerja model.

3.2 Hipotesis

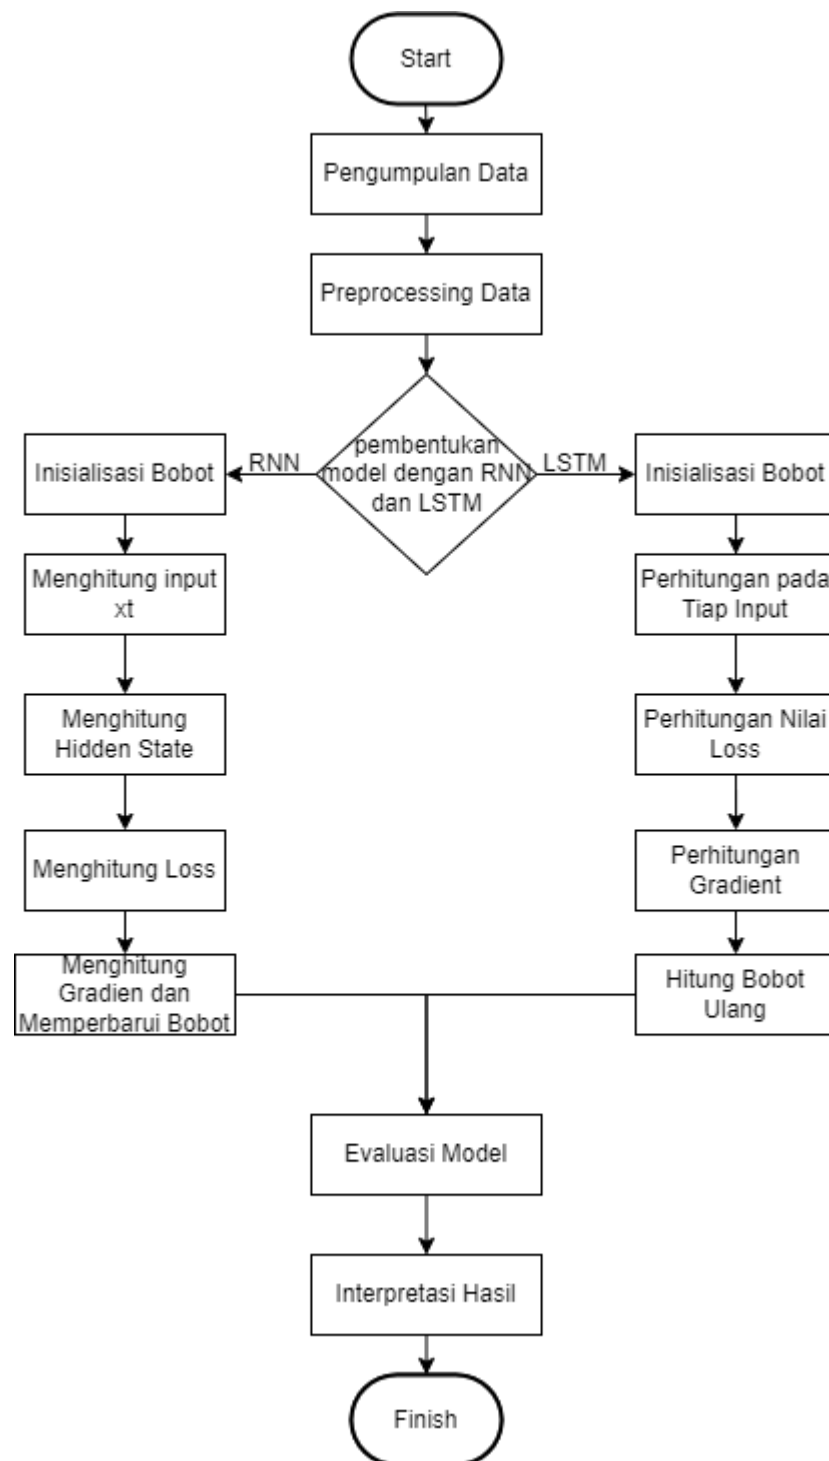
Hipotesis pada penelitian ini didasarkan pada asumsi bahwa algoritma yang digunakan untuk melakukan pengolahan data yang berbasis *time series* seperti algoritma RNN dan LSTM memiliki potensi untuk secara efektif membuat model berdasarkan pola temporal dalam data berat sampah harian. Berdasarkan rumusan

masalah pada penelitian ini maka, penelitian ini memiliki hipotesis utama yaitu model yang dihasilkan dari proses algoritma LSTM akan memiliki tingkat akurasi yang lebih baik daripada model yang dihasilkan dari algoritma RNN. Hipotesis tersebut didasarkan pada model LSTM memiliki arsitektur yang lebih kompleks dan mampu mempelajari hubungan temporal yang lebih jauh, berkat unit memori jangka panjangnya. Dengan demikian, LSTM mungkin lebih baik dalam menangkap pola-pola kompleks dan hubungan jangka panjang dalam data sampah, yang mungkin sulit dipelajari oleh model RNN yang lebih sederhana. Hipotesis ini akan dibuktikan dengan perbandingan *Mean Square Error* yang dihasilkan oleh model dari algoritma RNN dan LSTM yang telah dilatih.

Hipotesis dalam penelitian prediksi berat sampah dengan menggunakan algoritma *Recurrent Neural Network* (RNN) dan *Long Short Term Memory* (LSTM) menyatakan bahwa model yang dilatih dengan *batch size* 8, 100 *epoch*, dan menggunakan *optimizer* ADAM akan menghasilkan prediksi yang efisien. Pemilihan *batch size* 8 diharapkan dapat mempercepat proses pelatihan tanpa mengorbankan stabilitas konvergensi model. Dengan 100 *epoch*, model diharapkan memiliki cukup iterasi untuk belajar pola kompleks dalam data berat sampah secara efisien. Penggunaan *optimizer* ADAM dipilih karena kemampuannya yang unggul dalam penyesuaian parameter, yang dapat mempercepat konvergensi dan meningkatkan kinerja model dengan cara menggabungkan keuntungan dari *adaptive learning rate* dan momentum. Maka dari itu, hipotesis ini mengasumsikan bahwa konfigurasi ini akan memberikan keseimbangan optimal antara kecepatan pelatihan dan akurasi prediksi, sehingga model yang telah dilatih mampu memprediksi berat sampah dengan tingkat kesalahan yang minimal. Model dapat dikatakan efisien apabila memiliki komputasi yang rendah. Efisiensi model dilihat dari waktu eksekusi terhadap model yang dibangun baik dengan algoritma RNN maupun LSTM.

3.3 Tahap Rancangan Percobaan

Tahap rancangan percobaan dalam penelitian ini sebagaimana dijelaskan pada Gambar 3.2 Tahap Rancangan Percobaan berikut.



Gambar 3. 2 Tahap Rancangan Percobaan

Tahap rancangan percobaan yang pertama yaitu pengumpulan data. Data yang telah terkumpul yaitu sejumlah 1095 data yang didapatkan di TPA Klegen, data tersebut memiliki variabel berupa tanggal, armada pengangkut, waktu, dan berat sampah. Tahap selanjutnya yaitu *preprocessing* data, pada tahap ini dilakukan pembersihan data apabila ada nilai data yang hilang dan ketidak konsistenan data. Tahap ini juga data dilakukan normalisasi agar data berada pada skala yang sesuai untuk melakukan pemodelan. *Preprocessing* data juga dilakukan pembagian dataset menjadi *training* data dan *testing* data.

Tahap rancangan percobaan yang ketiga yaitu pembentukan model. Tahap ini dilakukan pemilihan arsitektur termasuk jumlah lapisan dan neuron pada setiap lapisan dari arsitektur RNN dan LSTM yang akan digunakan. Model kemudian dilatih dengan training dataset dengan mengoptimalkan beberapa parameter yang digunakan seperti *learning rate*, *batch size*, dan jumlah *epoch*. Tahap rancangan percobaan keempat adalah evaluasi model, dengan metrik evaluasi *Root Mean Square Error* (RMSE). Tahap rancangan percobaan terakhir yaitu interpretasi hasil. Hasil kinerja dan prediksi model dianalisis untuk mendapatkan jawaban dari rumusan masalah penelitian.

3.4 Tahap Pengujian

Tahapan pengujian Tahap pengujian penelitian prediksi berat sampah dengan menggunakan algoritma *Recurrent Neural Network* (RNN) dan *Long Short Term Memory* (LSTM) melibatkan beberapa langkah penting untuk memastikan akurasi dan keandalan model. Data historis berat sampah TPA Kabupaten Magelang yang telah terkumpul dilakukan *preprocessing* untuk menghilangkan anomali dan mengatasi nilai yang hilang. Data ini kemudian dibagi menjadi data pelatihan dan data pengujian. Model RNN dan LSTM dilatih menggunakan data pelatihan untuk menemukan konfigurasi terbaik yang meminimalkan kesalahan prediksi. Model diuji menggunakan data pengujian untuk mengevaluasi kinerjanya. Evaluasi kinerja algoritma yang dilakukan pada penelitian ini yaitu menggunakan *root mean squared error* (RMSE).

BAB IV

HASIL DAN PEMBAHASAN

4.1 Hasil


4.1.1 Pengumpulan data

Penelitian ini menggunakan sumber data dari catatan timbangan sampah di Tempat Pembuangan Akhir (TPA) Kabupaten Magelang selama periode tiga tahun, yaitu dari tahun 2021 hingga 2023. Dataset ini mencatat berat sampah yang masuk ke TPA selama periode tersebut. Data ini menjadi dasar untuk analisis dan penelitian terkait prediksi sampah di wilayah Kabupaten Magelang. Dataset ini memiliki variabel tanggal, dum truck / arm roll, pick up, tosa / roda 3, jumlah kendaraan, berat (kg), dan keterangan seperti yang terlihat pada tabel 4.1 Dataset TPA Kabupaten Magelang.

Tabel 4. 1 Dataset TPA Kabupaten Magelang

TANGGAL	DUM TRUCK / ARM ROLL		PICK UP		TOSA / RODA 3		JUMLAH KENDARAAN	BERAT (kg)	KETERANGAN
	JUMLAH RITASI	BERAT (kg)	JUMLAH RITASI	BERAT (kg)	JUMLAH RITASI	BERAT (kg)			
1	20,00	47.155,00	8,00	8.170,00	-	-	28,00	55.325,00	
2	23,00	46.740,00	7,00	8.345,00	-	-	30,00	55.085,00	
3	29,00	67.165,00	14,00	13.900,00	1,00	280,00	44,00	81.345,00	

Variabel tanggal merupakan tanggal pada saat data masuk ke TPA Kabupaten Magelang yang dicatat setiap hari selama jam operasional diberlakukan. Dum truck / arm roll merupakan variabel yang berisikan data jumlah ritasi dum truck / arm roll yang masuk ke TPA Kabupaten Magelang selama satu hari beserta berat sampah yang diangkut dalam bentuk kg yang sudah dijumlahkan selama satu hari. Variabel pick up juga berisi jumlah ritasi dan berat dalam sampah dalam satuan kg selama satu hari. Variabel tosa / roda 3 berisikan jumlah ritasi dan berat dalam satuan kg selama satu hari. Jumlah kendaraan adalah variabel yang berisikan jumlah kendaraan yang masuk ke TPA Kabupaten Magelang selama satu hari. Variabel berat (kg) berisikan total berat harian dalam satuan kilogram yang masuk ke TPA Kabupaten Magelang. Keterangan merupakan variabel yang berisikan keterangan hari apabila operasional TPA Kabupaten Magelang tidak berjalan secara semestinya.



Gambar 4. 1 Data Berat Sampah TPA Kabupaten Magelang

Data berat sampah dari TPA Kabupaten Magelang tahun 2021 hingga 2023 terdistribusi seperti pada Gambar 4.1 Data Berat Sampah TPA Kabupaten Magelang diatas. Grafik tersebut menunjukkan tren berat sampah harian dalam kilogram (kg) dari Januari 2021 hingga Desember 2023. Sumbu horizontal (x) menunjukkan rentang waktu dalam bentuk tanggal, sementara sumbu vertikal (y) menunjukkan berat sampah dalam satuan kilogram. Berat sampah mengalami fluktuasi signifikan setiap harinya, dengan beberapa puncak yang mencapai lebih dari 150.000 kg.

4.1.2 Persiapan Data

4.1.2.1 Import library

Library python di *import* dalam *tools* google collaboratory untuk dapat menggunakan fungsi, kelas, dan variabel. *Library* yang digunakan dalam penelitian ini seperti pada gambar 4.2 *Library* dibawah. *Library* yang digunakan yaitu *library numpy*, *pandas*, dan *time*. *Library numpy* digunakan untuk melakukan perhitungan saintifik. Pengolahan data berupa *cleaning* data, *transform*, juga pengelompokan data, fungsi baca format file dengan berbagai ekstensi, dan memudahkan *import* dan *eksport* data memanfaatkan *library pandas*. *Library matplotlib* difungsikan untuk membuat grafik dan plot. *Import drive* difungsikan untuk mengakses google drive dari notebook collaboratory. *Tensorflow.keras.layer* merupakan *library* untuk

menyediakan lapisan untuk membangun jaringan neural. *Library* tensorflow.keras.models berfungsi untuk membangun dan melatih model pembelajaran yang dibangun. Pemrosesan data digunakan *library* sklearn.preprocessing. Fungsi evaluasi kinerja model pembelajaran menggunakan fungsi sklearn.metrics.

```
[1] import numpy as np
import pandas as pd
from matplotlib import pyplot as plt
from google.colab import drive
from tensorflow.keras.layers import Dense, Dropout, LSTM, SimpleRNN
from tensorflow.keras.models import Sequential
from sklearn.preprocessing import MinMaxScaler
from sklearn.metrics import mean_squared_error, mean_absolute_error, r2_score
from tensorflow.keras.optimizers import Adam
from tensorflow.keras.initializers import HeNormal
import time
```

Gambar 4. 2 Library

4.1.2.2 Koneksi drive

```
[2] # Mount Google Drive
drive.mount('/content/drive')

# Load dataset
data = pd.read_csv('/content/drive/MyDrive/skripsi/data21-23.csv')
```

Mounted at /content/drive

Gambar 4. 3 Koneksi

Kode yang terlihat dalam gambar 4.3 Koneksi dimaksudkan untuk mengakses dan memproses dataset yang disimpan di Google Drive menggunakan lingkungan Google Collaboratory. Perintah `drive.mount('/content/drive')` digunakan untuk menghubungkan akun Google Drive dengan lingkungan kerja saat ini. Permintaan untuk mengakses file yang ada di Google Drive pada pengguna akan muncul, setelah disetujui akan dipasang ke dalam direktori `/content/drive` di lingkungan Colab. Source code selanjutnya pada gambar 4.3 Koneksi yaitu `data = pd.read_csv('/content/drive/MyDrive/skripsi/data21-23.csv')` memuat dataset dari file CSV yang berada di dalam Google Drive. Lokasi file ini adalah `/content/drive/MyDrive/skripsi/data21-23.csv`, dan fungsi `pd.read_csv()` dari library Pandas digunakan untuk membaca file CSV tersebut dan memuat isinya ke

dalam variabel `data` sebagai sebuah DataFrame. DataFrame ini kemudian dapat digunakan untuk analisis lebih lanjut dalam penelitian ini.

4.1.3 Pre Processing

Data yang telah dikumpulkan akan melalui dua tahapan pre-processing. Tahap pertama adalah menghilangkan nilai yang hilang (*missing value*) dari dataset. Tahap kedua adalah normalisasi data untuk memastikan bahwa variabel-variabel memiliki skala yang seragam. Dengan demikian, data yang digunakan dalam analisis lebih siap untuk diolah.

4.1.3.1 Missing value

Dataset yang digunakan terdapat beberapa data berat sampah yang kosong, dari 1095 data terdapat 122 data yang memiliki nilai kosong (*missing value*). Penyebab nilai kosong ini bervariasi, termasuk timbangan yang mati, kesalahan pada timbangan, pemadaman listrik, dan hari libur. Dataset yang belum dilakukan penghilangan missing value dapat dilihat pada gambar 4.4 Info Dataset dibawah. Gambar tersebut menunjukkan bahwa total jumlah variabel adalah 1095 variabel dilihat dari variabel nomor. Variabel jumlah kendaraan terisi 1072 data yang tidak kosong, sementara variabel berat(kg) memiliki 973 data yang terisi. *Missing value* akan diperlakukan dengan melakukan imputasi dengan interpolasi dengan metode linear.

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1095 entries, 0 to 1094
Data columns (total 4 columns):
#   Column          Non-Null Count  Dtype
---  -
0   no              1095 non-null   int64
1   tanggal         1095 non-null   object
2   jumlah_kendaraan 1072 non-null   float64
3   berat(kg)       973 non-null    float64
dtypes: float64(2), int64(1), object(1)
memory usage: 34.3+ KB
None
```

Gambar 4. 4 Info Dataset

Imputasi *missing value* menyebabkan data berubah menjadi 1095 data seperti yang terlihat pada gambar 4.5 Info Data 2. Gambar tersebut menjelaskan bahwa tampilan informasi DataFrame yang terdiri dari 1095 entri data, dengan rentang waktu dari 1 Januari 2021 hingga 31 Desember 2023, menunjukkan bahwa

data tersebut terindeks berdasarkan tanggal (*Date time Index*). DataFrame ini memiliki dua kolom yaitu jumlah kendaraan dan berat (kg). Kolom jumlah kendaraan memiliki 1095 entri yang tidak memiliki nilai kosong (non-null) dan berisi data bertipe `int64`. Kolom berat(kg) juga memiliki 1095 entri non-null dan bertipe `int64`.

```
>>> <class 'pandas.core.frame.DataFrame'>
DatetimeIndex: 1095 entries, 2021-01-01 to 2023-12-31
Data columns (total 3 columns):
#   Column          Non-Null Count  Dtype
---  -
0   no              1095 non-null   int64
1   jumlah_kendaraan 1095 non-null   int64
2   berat(kg)        1095 non-null   int64
dtypes: int64(3)
memory usage: 34.2 KB
None
```

Gambar 4. 5 Info Data 2

4.1.3.2 Normalization

Normalisasi data dilakukan untuk menyamakan skala variabel yang digunakan. Hasil normalisasi dari variabel berat(kg) dapat dilihat perbandingannya dari gambar 4.6 Data Sebelum Normalisasi dan gambar 4.7 Data sesudah Normalisasi dibawah ini.

tanggal	jumlah_kendaraan	berat(kg)
2021-01-01	49.0	94475.0
2021-01-02	80.0	139499.0
2021-01-03	55.0	97312.0
2021-01-04	84.0	142014.0
2021-01-05	76.0	129520.0

Gambar 4. 6 Data sebelum Normalisasi

tanggal	jumlah_kendaraan	berat(kg)
2021-01-01	49	0.558237
2021-01-02	80	0.824530
2021-01-03	55	0.575016
2021-01-04	84	0.839405
2021-01-05	76	0.765509

Gambar 4. 7 Data setelah Normalisasi

4.1.4 Build model

Proses *pre-processing* menghasilkan 973 data dapat digunakan untuk penelitian ini. Data kemudian dibagi menjadi 80% untuk pelatihan dan 20% untuk pengujian. Data pelatihan diacak untuk memastikan tidak ada urutan tertentu yang mendominasi. Data juga dipecah menjadi fitur (x_{train} , x_{test}) dan target (y_{train} , y_{test}). Pembentukan model dilakukan menggunakan dua algoritma secara terpisah yaitu algoritma RNN dan algoritma LSTM. Model dibangun menggunakan Keras, serta mengukur waktu yang diperlukan untuk melatih model tersebut. Model ini terdiri dari tiga lapisan layer, masing-masing dengan *dropout*, dan satu lapisan *dense* untuk keluaran akhir. Fungsi kerugian yang digunakan adalah MSE dengan *optimizer* Adam.

4.2 Pembahasan

Penelitian ini dilakukan dengan menggunakan dataset dari TPA Kabupaten Magelang. Dataset berisikan 1095 data yang pada proses pre-processing data dilakukan pengecekan nilai kosong dan mendapati 122 data terdapat nilai kosong. Nilai kosong tersebut terjadi dikarenakan beberapa hal diantaranya seperti timbangan mati, listrik pada area TPA padam, timbangan belum di tera, timbangan belum beroperasi, libur operasional TPA karena bertepatan dengan hari raya seperti Hari Raya Idul Fitri dan Hari Raya Idul Adha, libur operasional TPA karena ada kegiatan seperti bersih-bersih TPA, kunjungan staf kementerian, dan kunjungan menteri DLH seperti yang tertera pada tabel 4.2 *Missing Value* dibawah ini.

Tabel 4. 2 Missing Value

No.	Jumlah hari	Tanggal	Penyebab data kosong
1.	6 hari	28/02/2021 – 04/03/2021	Timbangan Mati
2.	1 hari	16/03/2021	Timbangan Mati
3.	1 hari	13/05/2021	Libur Idul Fitri
4.	1 hari	04/07/2021	Mati Listrik
5.	1 hari	10/07/2021	Mati Listrik
6.	1 hari	20/07/2021	Libur Idul Adha
7.	80 hari	11/12/2021 – 28/02/2022	Timbangan Mati
8.	10 hari	01/03/2022 – 10/03/2022	Timbangan Belum di Tera

No.	Jumlah hari	Tanggal	Penyebab data kosong
9.	1 hari	02/05/2022	Libur Idul Fitri
10.	1 hari	03/06/2022	Libur Bersih-bersih TPA
11.	1 hari	09/07/2022	Libur Idul Adha
12.	1 hari	14/07/2022	Kunjungan Staff Kementrian
13.	1 hari	20/07/2022	Kunjungan Mentri DLH
14.	16 hari	01/01/2023 – 16/01/2023	Timbangan Belum Beroperasi
15.	1 hari	22/04/2023	Libur Idul Fitri

Tabel 4.2 *missing value* di atas merinci periode dan alasan hilangnya data berat di TPA Kabupaten Magelang dari tahun 2021 hingga tahun 2023. Penyebab data hilang yang beragam pada beberapa periode seperti timbangan mati yang menyebabkan data hilang selama 6 hari dari 28 Februari 2021 hingga 4 Maret 2021, serta 1 hari pada 16 Maret 2021 dan periode panjang 80 hari dari 11 Desember 2021 hingga 28 Februari 2022. Libur Idul Fitri dan Idul Adha juga menyebabkan data kosong masing-masing selama 1 hari pada 13 Mei 2021, 20 Juli 2021, 2 Mei 2022, 9 Juli 2022, dan 22 April 2023. Mati listrik mengakibatkan hilangnya data pada 4 dan 10 Juli 2021, sementara penimbangan yang belum di tera mengakibatkan data kosong selama 10 hari dari 1 hingga 10 Maret 2022. Kunjungan staf Kementerian dan Menteri DLH juga menyebabkan hilangnya data masing-masing pada 14 dan 20 Juli 2022. Libur bersih-bersih TPA dan timbangan yang belum beroperasi juga menyebabkan data kosong masing-masing pada 3 Juni 2022 dan selama 16 hari dari 1 hingga 16 Januari 2023.

Preprocessing data yang dilakukan pada pengolahan data ini setelah dilakukan pengecekan *missing value* yaitu melakukan preprocessing data. Data yang telah dilakukan normalisasi dapat dilihat pada gambar diatas. Perolehan nilai data seperti gambar diatas dapat dijabarkan sebagai berikut.

$$data\ 1 = \frac{data\ n - min}{max - min} = \frac{94475 - 90}{169167 - 90} = 0,558237.$$

$$data\ 2 = \frac{data\ n - min}{max - min} = \frac{139499 - 90}{169167 - 90} = 0,824530.$$

$$data\ 3 = \frac{data\ n - min}{max - min} = \frac{97321 - 90}{169167 - 90} = 0,575016.$$

$$data\ 4 = \frac{data\ n-min}{max-min} = \frac{142014-90}{169167-90} = 0,839405.$$

$$data\ 5 = \frac{data\ n-min}{max-min} = \frac{129520-90}{169167-90} = 0,765509.$$

Data yang telah dilakukan preprocessing kemudian dilakukan pembagian data menjadi data *training* atau data latih dan data *testing* atau data uji. Data latih yang digunakan pada penelitian ini sebesar 80% dari 973 data atau berkisar 778 data dari 973 digunakan untuk data latih, sementara 20% dari 973 data atau 195 data digunakan sebagai data uji. Penelitian ini akan dicoba dengan beberapa parameter dengan jumlah yang berbeda. Berikut tabel 4.3 parameter yang merupakan rincian inisialisasi parameter yang digunakan saat melatih model.

Tabel 4. 3 Parameter

Parameter	Jumlah / Jenis
<i>Hidden Layer</i>	1 dan 2
Neuron	100
Optimizer	Adam
Fungsi Aktivasi	<i>linier</i>
<i>Epoch</i>	20, 50, 100, dan 200
<i>Batch Size</i>	4, 8, 10, 16, dan 20

Tabel 4.3 parameter di atas menggambarkan berbagai parameter yang digunakan dalam pelatihan model algoritma RNN dan LSTM dalam Prediksi berat sampah harian TPA Kabupaten Magelang. Parameter pertama adalah jumlah dan jenis *hidden layer*, yang bervariasi antara 1 *hidden layer* dan 2 *hidden layer*. Jumlah neuron di setiap *hidden layer* menggunakan 100 neuron. *Optimizer* yang digunakan adalah Adam, yang dikenal efektif dalam mengoptimalkan model. Fungsi aktivasi yang dipilih adalah fungsi *linier*, yang menghubungkan input langsung ke output tanpa transformasi non-linear. Proses pelatihan dilakukan dengan berbagai jumlah *epoch*, yaitu 20, 50, 100, dan 200 *epoch*, untuk melihat bagaimana model berkembang dengan lebih banyak iterasi pelatihan. Ukuran *batch* yang digunakan dalam pelatihan juga bervariasi, dengan nilai 4, 8, 10, 16, dan 20, yang menunjukkan berapa banyak sampel yang digunakan dalam satu kali pembaruan bobot model. Variasi dalam parameter-parameter ini bertujuan untuk menemukan kombinasi terbaik yang memberikan kinerja optimal model algoritma RNN dan LSTM.

Tabel 4. 4 Perbandingan Akurasi Algoritma RNN dan LSTM

Layer	Batch size	Epoch	RMSE RNN	RMSE LSTM
1	4	50	58893,009	51712,854
1	8	50	101127,063	46233,979
1	10	50	50848,564	47000,622
1	16	50	46409,931	46470,101
1	20	50	46112,246	46395,406
1	4	100	55031,121	41386,361
1	8	100	61891,720	44989,352
1	10	100	51114,518	47808,998
1	16	100	65821,017	47012,234
1	20	100	67031,397	46267,855
1	4	200	48069,256	42110,354
1	8	200	66317,119	40365,768
1	10	200	52627,514	41820,890
1	16	200	59644,269	47868,589
1	20	200	53198,637	45689,552
2	4	50	53665,520	45376,098
2	8	50	61910,734	51274,691
2	10	50	50021,534	54149,155
2	16	50	52551,216	55057,714
2	20	50	43696,105	52755,994
2	4	100	53131,941	43135,769
2	8	100	50815,603	45105,771
2	10	100	49461,612	44870,609
2	16	100	44942,606	43736,183
2	20	100	52735,668	44595,426
2	4	200	64695,299	39886,819
2	8	200	58360,229	43907,550
2	10	200	55032,039	46501,588
2	16	200	74169,660	48364,199
2	20	200	54364,832	47419,011

Tabel 4.4 Perbandingan akurasi algoritma RNN dan LSTM diatas menunjukkan perbandingan akurasi antara algoritma RNN dan LSTM, penelitian ini memberikan hasil bahwa model LSTM secara keseluruhan memiliki performa yang lebih unggul dibandingkan dengan RNN dalam hal akurasi prediksi. Nilai RMSE terendah yang dicapai oleh model RNN adalah 43696,105, sementara model LSTM berhasil mencapai nilai RMSE yang lebih rendah, yaitu 39886,819. Nilai RMSE yang lebih rendah ini menandakan bahwa LSTM memiliki kemampuan

yang lebih baik dalam memprediksi data dengan kesalahan yang lebih kecil dibandingkan dengan RNN.

Tabel 4.4 Perbandingan akurasi algoritma RNN dan LSTM memperlihatkan hasil perbandingan akurasi antara algoritma *Recurrent Neural Network* (RNN) dan *Long Short Term Memory* (LSTM) dalam memprediksi berat sampah harian di TPA. Parameter yang divariasikan meliputi jumlah layer, ukuran *batch*, dan jumlah *epoch*, yang masing-masing memiliki pengaruh terhadap nilai *Root Mean Square Error* (RMSE) sebagai ukuran akurasi. Pada konfigurasi RNN dengan satu layer, hasil menunjukkan bahwa peningkatan ukuran *batch* sering kali menyebabkan penurunan RMSE, mengindikasikan peningkatan akurasi model. Penambahan jumlah *epoch* dari 50 menjadi 100 juga secara umum menunjukkan penurunan RMSE, menandakan bahwa model yang dilatih lebih lama cenderung lebih akurat.

Jumlah layer yang ditingkatkan menjadi dua, menghasilkan pola hasil RNN menjadi lebih bervariasi. Peningkatan ukuran *batch* dan jumlah *epoch* pada beberapa percobaan tidak selalu menghasilkan penurunan RMSE. Hal ini menunjukkan bahwa kompleksitas tambahan yang ditambahkan dengan lapisan kedua tidak selalu menguntungkan untuk semua konfigurasi misalnya, pada ukuran *batch* kecil dengan dua layer, penambahan *epoch* terkadang justru tidak meningkatkan akurasi secara signifikan.

Model LSTM menunjukkan performa yang lebih konsisten dan unggul dibandingkan RNN dalam berbagai konfigurasi. Konfigurasi model LSTM dengan satu layer, secara umum menunjukkan penurunan RMSE yang lebih signifikan seiring dengan peningkatan ukuran *batch* dan jumlah *epoch*, hal tersebut menunjukkan bahwa LSTM, dengan mekanisme pengaturan memorinya yang lebih kompleks, lebih mampu menangani pola data yang lebih kompleks dan menghasilkan prediksi yang lebih akurat dibandingkan dengan RNN. Pada ukuran *batch* yang lebih besar dan jumlah *epoch* yang lebih tinggi, LSTM terus menunjukkan peningkatan akurasi, yang menegaskan keunggulannya dalam mempelajari dan mengingat pola jangka panjang dalam data.

Jumlah layer yang ditingkatkan menjadi dua menyebabkan LSTM tetap menunjukkan keunggulannya dalam hal akurasi prediksi. Peningkatan kompleksitas model LSTM dengan menambahkan layer kedua tidak selalu memberikan penurunan RMSE yang signifikan pada beberapa konfigurasi, LSTM secara konsisten menghasilkan nilai RMSE yang lebih rendah dibandingkan RNN. Hal ini mengindikasikan bahwa LSTM lebih efisien dalam memanfaatkan tambahan kompleksitas ini untuk mengoptimalkan akurasi prediksi. Secara keseluruhan, hasil perbandingan ini menegaskan bahwa LSTM lebih unggul dalam menangani data prediktif yang kompleks, terutama dalam konfigurasi dengan parameter yang lebih tinggi, membuatnya lebih cocok digunakan dalam aplikasi prediksi yang memerlukan akurasi tinggi.

Tabel 4. 5 Perbandingan Efektivitas RNN dan LSTM

Layer	Batch size	Epoch	RNN Runtime	LSTM Runtime
1	4	50	183,718	386,481
1	8	50	143,419	264,361
1	10	50	83,437	182,103
1	16	50	53,477	145,014
1	20	50	83,580	114,723
1	4	100	367,187	756,149
1	8	100	203,352	444,431
1	10	100	170,942	390,616
1	16	100	143,502	269,907
1	20	100	97,474	268,734
1	4	200	631,384	1285,224
1	8	200	443,712	926,449
1	10	200	444,220	807,730
1	16	200	242,109	491,081
1	20	200	204,117	511,332
2	4	50	444,729	803,315
2	8	50	265,147	439,492
2	10	50	154,195	334,857
2	16	50	144,086	234,491
2	20	50	108,127	240,458
2	4	100	804,862	1548,542
2	8	100	445,159	895,126
2	10	100	3246,426	690,456
2	16	100	265,109	569,541
2	20	100	182,644	448,589
2	4	200	1644,757	320,834


Layer	Batch size	Epoch	RNN Runtime	LSTM Runtime
2	8	200	864,680	1708,425
2	10	200	599,543	1287,516
2	16	200	444,151	980,236
2	20	200	383,995	809,227

Berdasarkan penelitian yang telah dilakukan, terlihat bahwa model *Recurrent Neural Network* (RNN) memiliki waktu *runtime* yang lebih efisien dibandingkan dengan model *Long Short Term Memory* (LSTM). Tabel 4.5 Perbandingan efektivitas RNN dan LSTM, model RNN menunjukkan *runtime* terpendek sebesar 53,477 detik, sementara *runtime* terpendek yang dicapai oleh model LSTM adalah 114,723 detik. Perbedaan ini mengindikasikan bahwa RNN mampu memproses data dengan kecepatan yang lebih tinggi dibandingkan LSTM. Efisiensi *runtime* yang lebih baik pada RNN dapat menjadi keuntungan signifikan dalam aplikasi yang memerlukan pemrosesan cepat.

Konfigurasi algoritma RNN seperti yang tertera pada tabel 4.5 Perbandingan efektivitas RNN dan LSTM dimana algoritma RNN dengan satu layer menunjukkan *runtime* yang lebih efisien dibandingkan dengan dua layer. Pada satu layer, *runtime* terpendek tercapai dengan ukuran *batch* 16 dan *epoch* 50, bertambahnya ukuran *batch* hingga 20, *runtime* model justru meningkat. Penambahan *epoch* dari 50 menjadi 100 dan 200 secara umum meningkatkan *runtime* secara signifikan, meskipun ukuran *batch* yang lebih besar dapat membantu mengurangi *runtime* dalam beberapa kasus percobaan yang dilakukan. Konfigurasi model RNN dengan dua layer menghasilkan *runtime* terendah tercapai pada ukuran *batch* 20 dan *epoch* 50. Penambahan *epoch* dari 50 menjadi 100 dan 200 juga menyebabkan peningkatan *runtime* yang cukup drastis. Percobaan ini menunjukkan bahwa penggunaan satu layer RNN dengan ukuran *batch* yang 16 dan jumlah *epoch* 50 dapat memberikan *runtime* yang paling efisien, sementara konfigurasi yang lebih kompleks menyebabkan *runtime* model menjadi lebih panjang.


Percobaan *running* yang dilakukan untuk mengevaluasi *runtime* pada algoritma *Long Short-Term Memory* (LSTM) dalam melakukan prediksi seperti pada tabel 4.5 Perbandingan efektivitas RNN dan LSTM, ditemukan bahwa penggunaan satu lapisan LSTM adalah yang paling efektif. Penambahan lapisan

LSTM justru meningkatkan *runtime* secara signifikan. Struktur lapisan yang lebih sederhana dengan satu lapisan LSTM mampu memberikan kinerja yang lebih efisien dalam hal waktu pemrosesan, dibandingkan dengan struktur yang lebih kompleks dengan beberapa lapisan. Selain itu, pada percobaan ini juga menunjukkan bahwa semakin besar ukuran *batch* yang digunakan, *runtime* cenderung menurun. Hal ini disebabkan oleh efisiensi komputasi yang lebih baik saat memproses data dalam *batch* yang lebih besar.



Gambar 4. 8 Berat Sampah kondisi Idul Fitri 2021

Gambar 4.8 Berat sampah kondisi Idul Fitri 2021 diatas menunjukkan sebuah grafik garis yang menggambarkan data berat dalam kilogram (kg) pada rentang waktu dari 12 Mei 2021 hingga 19 Mei 2021. Pada sumbu horizontal (sumbu-X), tanggal-tanggal ditampilkan, sementara pada sumbu vertikal (sumbu-Y), berat dalam kilogram ditampilkan. Hari H hari raya Idul Fitri terjadi pada 13 Mei 2021, dapat dilihat pada grafik bahwa pada tanggal 13 Mei 2021 tidak ada berat sampah yang masuk. Pekan Idul Fitri 2021 berat sampah yang masuk ke TPA mengalami kenaikan signifikan pada H+2 Idul Fitri, sementara itu mengalami kenaikan puncak pada H+5 Lebaran Idul Fitri.




Gambar 4. 9 Berat Sampah Kondisi Idul Fitri 2022

Gambar 4.9 Berat sampah kondisi Idul Fitri 2022 diatas menunjukkan sebuah grafik garis yang menggambarkan data berat dalam kilogram (kg) pada rentang waktu dari 01 Mei 2022 hingga 09 Mei 2022. Sumbu horizontal (sumbu-X) menampilkan tanggal-tanggal, sementara pada sumbu vertikal (sumbu-Y) menampilkan berat sampah dalam kilogram. Hari H hari raya Idul Fitri terjadi pada 02 Mei 2022, dapat dilihat pada grafik bahwa pada tanggal tersebut tidak ada berat sampah yang masuk. Pekan Idul Fitri 2022 berat sampah yang masuk ke TPA mengalami kenaikan signifikan pada H+3 Idul Fitri, sementara itu mengalami kenaikan puncak pada H+5 Lebaran Idul Fitri.

Gambar 4.10 Berat sampah kondisi Idul Fitri 2023 dibawah menunjukkan sebuah grafik garis yang menggambarkan data berat dalam kilogram (kg) pada rentang waktu dari 21 April 2023 hingga 28 April 2023. Sumbu horizontal (sumbu-X) menampilkan tanggal-tanggal, sementara pada sumbu vertikal (sumbu-Y) menampilkan berat sampah dalam kilogram. Hari H hari raya Idul Fitri terjadi pada 22 April 2022, dapat dilihat pada grafik bahwa pada tanggal tersebut tidak ada berat sampah yang masuk. Pekan Idul Fitri 2022 berat sampah yang masuk ke TPA

mengalami kenaikan signifikan pada H+3 Idul Fitri, sementara itu mengalami kenaikan puncak pada H+5 Lebaran Idul Fitri.




Gambar 4. 10 Berat Sampah Kondisi Idul Fitri 2023

Ketiga grafik diatas merupakan grafik pola pembuangan sampah yang ada di TPA Kabupaten Magelang selama tiga tahun yang menampilkan kondisi saat ada hari libur Idul Fitri. Aktivitas pembuangan sampah di TPA Kabupaten Magelang dipengaruhi oleh aktivitas libur saat ada hari besar seperti libur Idul Fitri. Libur Idul Fitri menyebabkan banyak usaha, pasar, dan rumah tangga mengurangi aktivitas, yang menyebabkan berat sampah yang dihasilkan menurun. Waktu liburan yang panjang menyebabkan layanan pengumpulan sampah berkurang atau tertunda, sehingga sampah yang diangkut ke TPA juga berkurang. Manajemen sampah yang terakumulasi sebelum liburan juga berpengaruh. Banyak warga dan bisnis melakukan pembersihan menyeluruh sebelum liburan, yang mengakibatkan penurunan sementara dalam produksi sampah setelah liburan.

Grafik visualisasi diatas menunjukkan kesamaan pola bahwa setelah adanya libur Idul Fitri pola pengumpulan sampah di TPA Kabupaten Magelang akan mengalami kenaikan signifikan pada h+4 lebaran Idul Fitri. Anomali berat sampah tersebut disebabkan oleh jam operasional TPA Kabupaten Magelang yang mengalami perubahan pada h+1 hingga h+3 lebaran Idul Fitri yang mana Jam


operasional TPA buka hingga jam 10.00 WIB. Data prediksi yang akan datang juga menunjukkan adanya anomali berat sampah yang sama dengan data pada tahun-tahun berikutnya. Prediksi tahun 2024 untuk anomali berat sampah ketika hari libur lebaran dapat dilihat pada gambar 4.12 Prediksi berat sampah pada Idul Fitri 2024 dibawah. Grafik tersebut merupakan grafik prediksi berat pada tahun 2024 ketika hari raya Idul Fitri, dengan sumbu x yang menggambarkan tanggal dari 10 April hingga 16 April 2024, dan sumbu y yang merepresentasikan nilai berat. 2024, berat berada pada nilai yang relatif rendah, dengan sedikit kenaikan pada 11 April 2024. Mulai 12 April hingga 13 April 2024, terdapat peningkatan berat yang tajam hingga mencapai puncaknya pada 13 April 2024. Berat mengalami penurunan setelah mencapai puncak, mulai 14 April 2024 berat sampah mengalami penurunan hingga akhir pekan Idul Fitri 2024



Gambar 4. 11 Prediksi Berat Sampah pada Idul Fitri 2024


Gambar 4.12 Berat sampah kondisi Idul Adha 2021 dibawah menunjukkan sebuah grafik garis yang menggambarkan data berat dalam kilogram (kg) pada rentang waktu dari 19 Juli 2021 hingga 26 Juli 2021. Sumbu horizontal (sumbu-X) menampilkan tanggal-tanggal, sementara pada sumbu vertikal (sumbu-Y) menampilkan berat sampah dalam kilogram. Hari H hari raya Idul Adha terjadi pada 20 Juli 2021, dapat dilihat pada grafik bahwa pada tanggal tersebut tidak ada berat

sampah yang masuk. Pekan Idul Adha 2021 berat sampah yang masuk ke TPA mengalami kenaikan signifikan pada H+1 Idul Adha, dimana hari tersebut merupakan kenaikan puncak pada Lebaran Idul Adha 2021.



Gambar 4. 12 Berat Sampah Kondisi Idul Adha 2021


Gambar 4.13 Berat sampah kondisi Idul Adha 2022 dibawah menunjukkan sebuah grafik garis yang menggambarkan data berat dalam kilogram (kg) pada rentang waktu dari 09 Juli 2022 hingga 16 Juli 2022. Sumbu horizontal (sumbu-X) menampilkan tanggal-tanggal, sementara pada sumbu vertikal (sumbu-Y) menampilkan berat sampah dalam kilogram. Hari H hari raya Idul Adha terjadi pada 10 Juli 2022, dapat dilihat pada grafik bahwa pada tanggal tersebut tidak ada berat sampah yang masuk. Pekan Idul Adha 2022 berat sampah yang masuk ke TPA mengalami kenaikan signifikan pada H+4 Idul Adha, sementara itu mengalami kenaikan puncak pada H+4 Lebaran Idul Adha dengan berat sampah sebesar 132510 kg.



Gambar 4. 13 Berat Sampah Kondisi Idul Adha 2022

Gambar 4.14 Berat sampah kondisi Idul Adha 2023 dibawah menunjukkan sebuah grafik garis yang menggambarkan data berat dalam kilogram (kg) pada rentang waktu dari 28 Juni 2023 hingga 05 Juli 2023. Sumbu horizontal (sumbu-X) menampilkan tanggal-tanggal, sementara pada sumbu vertikal (sumbu-Y) menampilkan berat sampah dalam kilogram. Hari H hari raya Idul Adha terjadi pada 29 Juni 2023, dapat dilihat pada grafik bahwa pada tanggal tersebut tidak ada berat sampah yang masuk. Pekan Idul Adha 2023 berat sampah yang masuk ke TPA mengalami kenaikan signifikan pada H+2 Idul Adha, sementara itu mengalami kenaikan puncak pada H+2 Lebaran Idul Adha.

Berat sampah pekan Idul Adha 2023 memiliki berat tertinggi pada H+2 dengan berat sampah sebesar 98785.00 kg. Berat sampah Idul Adha 2023 mengalami perubahan pola dari tahun 2021 dan 2022 hal tersebut dikarenakan operasional TPA yang mengalami perubahan. Operasional TPA Labupaten Magelang pada tahun 2023 tidak ada libur pada waktu Idul Adha sehingga sampah yang terkumpul dapat didistribusikan pada hari tersebut tanpa mengalami penumpukan yang mengakibatkan kenaikan tajam pada satu hari setelah Hari Raya Idul Adha.




Gambar 4. 14 Berat Sampah Kondisi Idul Adha 2023

Grafik diatas menunjukkan anomali berat sampah ketika hari Raya Idul Adha terjadi. Grafik tahun 2021 dan 2022 menunjukkan bahwa berat sampah langsung mengalami kenaikan setelah adanya libur lebaran Idul Adha, sedangkan pada tahun 2023 TPA Kabupaten Magelang tidak memberlakukan libur pada saat hari Raya Idul Adha. Operasional TPA Kabupaten Magelang tetap dijalankan dengan jam operasional yang sama dengan hari-hari biasa. TPA Kabupaten Magelang tetap beroperasi, akan tetapi kenaikan berat sampah tetap terjadi meskipun dalam pola yang berbeda dibandingkan tahun-tahun sebelumnya. Peningkatan signifikan dalam berat sampah pada hari setelah Idul Adha menunjukkan bahwa meskipun TPA tetap buka, berat sampah yang dihasilkan masyarakat pada hari raya tersebut sangat besar, sehingga terjadi penumpukan yang perlu segera ditangani.

Perubahan kebijakan ini menunjukkan bahwa meskipun operasional TPA terus berjalan, faktor budaya dan kebiasaan masyarakat dalam membuang sampah selama hari raya tetap mempengaruhi pola pengumpulan sampah, yang memerlukan perhatian khusus dalam pengelolannya. Hari libur memberikan pengaruh terhadap berat sampah yang masuk ke TPA Kabupaten Magelang, ketika

TPA berhenti beroperasi selama hari raya, penumpukan sampah tidak bisa dihindari. Penghentian sementara operasional TPA menyebabkan sampah menumpuk di berbagai titik pengumpulan di berbagai wilayah, baik di tempat sampah rumah tangga maupun di tempat pembuangan sementara (TPS). Berat Sampah pada hari pertama setelah operasional TPA dilanjutkan mengalami lonjakan tajam karena hal tersebut. Lonjakan berat sampah membuat sebuah tantangan dalam operasional TPA, karena harus menangani volume sampah yang jauh lebih besar dalam waktu singkat. Diperlukan strategi khusus dalam pengelolaan sampah selama periode hari raya, termasuk mempertimbangkan operasional terbatas atau alternatif pengelolaan sampah selama hari libur untuk mengurangi dampak penumpukan sampah.



Gambar 4. 15 Prediksi Berat Sampah pada Idul Adha 2024

Grafik pada gambar 4.15 Prediksi Berat Sampah pada Idul Adha 2024 menunjukkan adanya tren kenaikan berat sampah yang diikuti dengan fluktuasi signifikan dalam rentang waktu pendek. Hari Raya Idul Adha 2024 terjadi pada tanggal 17 Juni 2024. Grafik diatas menunjukkan tren yang sama dengan grafik berat sampah pada pekan Hari Raya Idul Adha pada tahun 2023. Berat sampah diperkirakan akan mengalami kenaikan yang signifikan pada H+2 Hari Raya Idul Adha. Berat sampah mengalami puncak berat pada hari terakhir pekan Idul Adha 2024 pada 97902,65 kg.

BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Penelitian ini menunjukkan bahwa algoritma *Long Short Term Memory* (LSTM) memiliki performa yang lebih baik dalam hal akurasi prediksi berat sampah harian di Tempat Pemrosesan Akhir (TPA) Kabupaten Magelang dibandingkan dengan *Recurrent Neural Network* (RNN). Kedua algoritma ini mampu memberikan hasil prediksi yang cukup baik, namun LSTM secara konsisten unggul dalam hal akurasi. LSTM mampu mencapai nilai *Root Mean Square Error* (RMSE) terendah sebesar 39886,819 dengan konfigurasi batch size 4 dan 200 epoch. Sebagai perbandingan, model RNN hanya mampu mencapai RMSE terendah sebesar 43696,105 dengan konfigurasi dua layer, batch size 20, dan 50 epoch. Perbedaan nilai RMSE ini mengindikasikan bahwa algoritma LSTM memiliki kemampuan yang lebih baik dalam meminimalkan kesalahan prediksi, yang berarti prediksi yang dihasilkan oleh LSTM lebih akurat dibandingkan dengan RNN.

Penelitian ini juga mengungkapkan bahwa dari segi efisiensi runtime, model *Recurrent Neural Network* (RNN) menunjukkan keunggulan yang signifikan dibandingkan dengan model *Long Short Term Memory* (LSTM). Model RNN memiliki runtime terpendek sebesar 53,477 detik dengan konfigurasi batch size 16 dan 50 epoch, yang menunjukkan bahwa RNN dapat menyelesaikan proses pelatihan dan prediksi dengan waktu yang lebih singkat. Sebaliknya, model LSTM dengan konfigurasi satu lapisan, batch size 20, dan 50 epoch memiliki runtime terpendek sebesar 114,723 detik, yang lebih dari dua kali lipat waktu yang dibutuhkan oleh RNN. Perbedaan ini menunjukkan bahwa meskipun LSTM lebih unggul dalam hal akurasi, RNN lebih efisien dalam penggunaan waktu. Efisiensi *runtime* ini menjadi faktor penting ketika kecepatan pemrosesan menjadi pertimbangan utama.

5.2 Saran

Berdasarkan kesimpulan diatas, maka diharapkan untuk penelitian selanjutnya dapat dikembangkan sebagai berikut:

1. Pemilihan Algoritma Berdasarkan Prioritas

Berdasarkan hasil penelitian, apabila prioritas utama adalah akurasi prediksi, maka algoritma *Long Short Term Memory* (LSTM) sebaiknya digunakan karena kemampuannya yang lebih baik dalam meminimalkan kesalahan prediksi. Namun, jika efisiensi runtime atau kecepatan pemrosesan lebih diutamakan, maka algoritma *Recurrent Neural Network* (RNN) dapat menjadi pilihan untuk digunakan dalam membuat model.

2. Optimalisasi Konfigurasi Model

Peningkatkan efisiensi dan akurasi yang lebih lanjut, dapat dilakukan eksperimen dengan berbagai konfigurasi parameter model, seperti jumlah layer, ukuran *batch*, dan jumlah *epoch*. Penelitian lanjutan dapat fokus pada menemukan konfigurasi optimal yang dapat memberikan keseimbangan terbaik antara akurasi dan runtime, baik untuk LSTM maupun RNN.

3. Penggunaan Model Hibrida

Pertimbangkan penggunaan model hibrida yang menggabungkan keunggulan RNN dan LSTM. Algoritma RNN dapat digunakan untuk tahap pemrosesan awal yang membutuhkan efisiensi waktu, diikuti oleh LSTM untuk tahap akhir yang membutuhkan akurasi tinggi. Pendekatan ini dapat memanfaatkan kekuatan kedua algoritma secara lebih efektif.

DAFTAR PUSTAKA

- Achmalia, A. F., & Sugiman, W. (2020). Peramalan Penjualan Semen menggunakan Backpropagation neural Network dan Recurrent Neural Network. *UNNES Journal of Mathematics*.
- Alim, M. N. (2023). *Pemodelan Time Series Data Saham LQ45 dengan Algoritma LSTM, RNN, dan Arima*. 6.
- Anifah, E. M., Rini, I. D. W. S., Hidayat, R., & Ridho, M. (2021). Estimasi emisi Gas Rumah Kaca (GRK) kegiatan Pengelolaan Sampah di Kelurahan Karang Joang, Balikpapan. *Jurnal Sains & Teknologi Lingkungan*, 13(1). <https://doi.org/10.20885/jstl.vol13.iss1.art2>
- Axmalia, A., & Mulasari, S. A. (2020). Dampak Tempat Pembuangan Akhir Sampah (TPA) Terhadap Gangguan Kesehatan Masyarakat. *Jurnal Kesehatan Komunitas*, 6(2), 171–176. <https://doi.org/10.25311/keskom.Vol6.Iss2.536>
- Ghozi, A. A., Aprianti, A., Dimas, A. D. P., & Fauzi, R. (2022). Analisis Prediksi Data Kasus Covid-19 di Provinsi Lampung Menggunakan Recurrent Neural Network (RNN). *Indonesian Journal of Applied Mathematics*, 2(1), 25. <https://doi.org/10.35472/indojam.v2i1.763>
- Jain, A., Zamir, A. R., Savarese, S., & Saxena, A. (2016). *Structural-RNN: Deep Learning on Spatio-Temporal Graphs* (arXiv:1511.05298). arXiv. <http://arxiv.org/abs/1511.05298>
- Kahfi, A. (2017). Tinjauan Terhadap Pengelolaan Sampah. *Jurisprudentie : Jurusan Ilmu Hukum Fakultas Syariah dan Hukum*, 4(1), 12. <https://doi.org/10.24252/jurisprudentie.v4i1.3661>
- Li, P., Wang, Q., Zhang, Q., Cao, S., Liu, Y., & Zhu, T. (2012). Non-destructive Detection on the Egg Crack Based on Wavelet Transform. *IERI Procedia*, 2, 372–382. <https://doi.org/10.1016/j.ieri.2012.06.104>
- Manikari, S. L., Astuti, R., & Basysyar, F. M. (2024). *Implementasi Algoritma Long Short Term Memory (LSTM) untuk Memprediksi Volume Sampah*. 8(3).
- McDougall, F., Franke, M., & Hindle, P. (2001). *Integrated Solid waste Management: Life Cycle Inventory Second Edition*. Blackwell Publishing Company.
- Nurhajati, N. (2022). *Implementasi Program Bank Sampah Berbasis Partisipasi Masyarakat Untuk Mengurangi Penumpukan Sampah Di Kabupaten Tulungagung*.
- Nurmahaludin. (2014). Analisis Perbandingan Metode Jaringan Syaraf Tiruan dan Regresi Linear Berganda pada prakiraan Cuaca. *Jurnal INTEKNA*, No 2, 102–209.
- Pemerintah Indonesia. (2008). *Undang-Undang Nomor 18 Tahun 2008 tentang Pengelolaan Sampah*.
- Priandila, N., Saripurna, D., & Simanjuntak, M. (n.d.). *Penerapan Metode Backpropagation untuk Memprediksi Jumlah Sampah (Studi Kasus :DLH Kab. Langkat)*.

- Purnamaswari, A. A. A., Darma Putra, I. K. G., & Suwija Putra, I. M. (2022). Komparasi Metode Neural Network Backpropagation dan Support Vector Machines dalam Prediksi Volume Sampah TPA Suwung. *JITTER : Jurnal Ilmiah Teknologi dan Komputer*, 3(1), 853. <https://doi.org/10.24843/JTRTI.2022.v03.i01.p21>
- Sejati, K. (2009). *Pengolahan Sampah Terpadu*. Kanisius.
- Selle, N., Yudistira, N., & Dewi, C. (2022). Perbandingan Prediksi Penggunaan Listrik dengan Menggunakan Metode Long Short Term Memory (LSTM) dan Recurrent Neural Network (RNN). *Jurnal Teknologi Informasi dan Ilmu Komputer*, 9(1), 155–162. <https://doi.org/10.25126/jtiik.2022915585>
- Sugiartawan, P., Jiwa Permana, A. A., & Prakoso, P. I. (2018). Forecasting Kunjungan Wisatawan Dengan Long Short Term Memory (LSTM). *Jurnal Sistem Informasi dan Komputer Terapan Indonesia (JSIKTI)*, 1(1), 43–52. <https://doi.org/10.33173/jsikti.5>
- Tarkus, E. D. (2020). *Implementasi Metode Recurrent Neural Network pada Pengklasifikasian Kualitas Telur Puyuh*. 15.
- Taufiq, A., & Maulana, M. F. (2015). *Sosialisasi Sampah Organik dan Non Organikserta pelatihan Kreasi sampah*. 4(1).
- Tauryawati, M. L., & Irawan, M. I. (2014). Perbandingan Metode Fuzzy Time Series Cheng dan Metode Box-Jenkins untuk Memprediksi IHSG, Mey Lista Tauryawati dan M.Isa.Irawan. *Jurnal Sains Dan Seni Pomits*, 3(No. 2), 34–39.
- Wanto, A., & Windarto, A. P. (2017). *Analisis Prediksi Indeks Harga Konsumen Berdasarkan Kelompok Kesehatan Dengan Menggunakan Metode Backpropagation*. 2.
- Yoani, A., Sediono, S., Mardianto, M. F. F., & Pusporani, E. (2023). Prediksi Jumlah Kejadian Banjir Bulanan di Indonesia Berdasarkan Analisis Long Short Term Memory. *G-Tech: Jurnal Teknologi Terapan*, 7(4), 1663–1672. <https://doi.org/10.33379/gtech.v7i4.3346>
- Yu, L., Chen, J., Ding, G., Tu, Y., Yang, J., & Sun, J. (2018). Spectrum Prediction Based on Taguchi Method in Deep Learning With Long Short-Term Memory. *IEEE Access*, 6, 45923–45933. <https://doi.org/10.1109/ACCESS.2018.2864222>

LAMPIRAN

1. Kondisi TPA Kabupaten Magelang

Gambar	Keterangan
	<p>Proses pencatatan berat sampah yang masuk ke TPA Kabupaten Magelang.</p>
	<p>Kondisi TPA Pasuruhan yang penuh dengan sampah disemua areanya.</p>
	<p>Jembatan timbang yang digunakan untuk melakukan penimbangan berat sampah yang masuk.</p>
	<p>Kondisi lahan pada TPA Klegen yang mulai dipenuhi oleh sampah.</p>